데이터 시각화

이산변수 시각화

1. 이산변수(discrete quantitative data) 시각화
   - 정수단위로 나누어 측정할 수 있는 변수

➢ barplot() 형식 – 막대차트 그리기 함수

```
help("barplot") # barplot() 함수 형식 보기

barplot(height, width = 1, space = NULL,
        names.arg = NULL, legend.text = NULL, beside = FALSE,
        horiz = FALSE, density = NULL, angle = 45,
        col = NULL, border = par("fg"),
        main = NULL, sub = NULL, xlab = NULL, ylab = NULL,
        xlim = NULL, ylim = NULL, xpd = TRUE, log = "",
        axes = TRUE, axisnames = TRUE,
        cex.axis = par("cex.axis"), cex.names = par("cex.axis"),
        inside = TRUE, plot = TRUE, axis.lty = 0, offset = 0,
        add = FALSE, args.legend = NULL, ...)
```

이산변수 시각화

- 시각화를 위한 데이터 셋 가져오기

```
# 막대차트 데이터 생성
chart_data <- c(305,450, 320, 460, 330, 480, 380, 520)
names(chart_data) <- c("2014 1분기","2015 1분기","2014 2분기","2015 2분기,
                       "2014 3분기","2015 3분기","2014 4분기","2015 4분기")
str(chart_data)
chart_data
```

이산변수 시각화

① 막대차트 시각화

➢ 세로 막대 차트

```
barplot(chart_data, ylim=c(0,600),
        col=rainbow(8), main ="2014년도 vs 2015년도 분기별 매출현황 비교")
barplot(chart_data, ylim=c(0,600), ylab="매출액(단위:만원)", xlab="년도별 분기현황",
        col=rainbow(8), main ="2014년도 vs 2015년도 분기별 매출현황 비교")
```

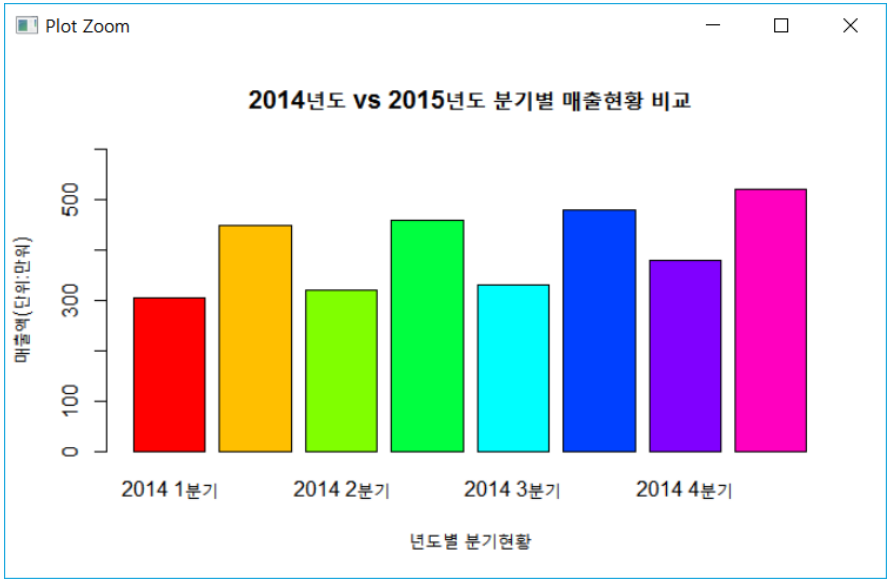

이산변수 시각화

① 막대차트 시각화

- 가로막대 차트 시각화

```
barplot(chart_data, xlim=c(0,600), horiz=TRUE,
        xlab="매출액(단위:만원)", ylab="년도별 분기현황",  col=rainbow(8),
        main ="2014년도 vs 2015년도 분기별 매출현황 비교")
```

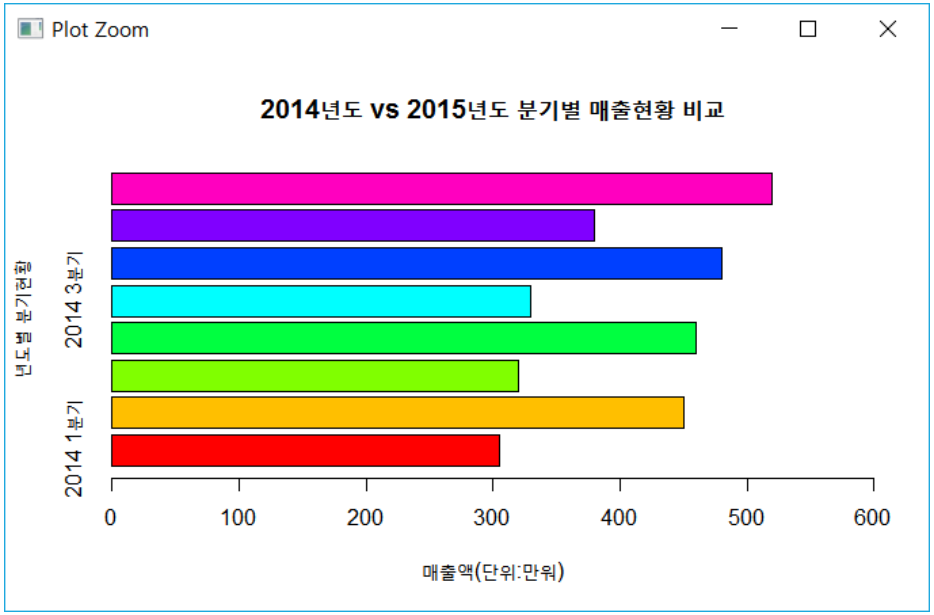

이산변수 시각화

- 1행 2열 차트 그리기

```
par(mfrow=c(1,2)) # 1행 2열 그래프 보기
barplot(VADeaths, beside=T,col=rainbow(5),
        main="미국 버지니아주 하위계층 사망비율")
legend(19, 71, c("50-54","55-59","60-64","65-69","70-74"), cex=0.8, fill=rainbow(5))

barplot(VADeaths, beside=F,col=rainbow(5))
title(main ="미국 버지니아주 하위계층 사망비율",font.main=4)
legend(3.8, 200, c("50-54","55-59","60-64","65-69","70-74"), cex=0.8, fill=rainbow(5))
```

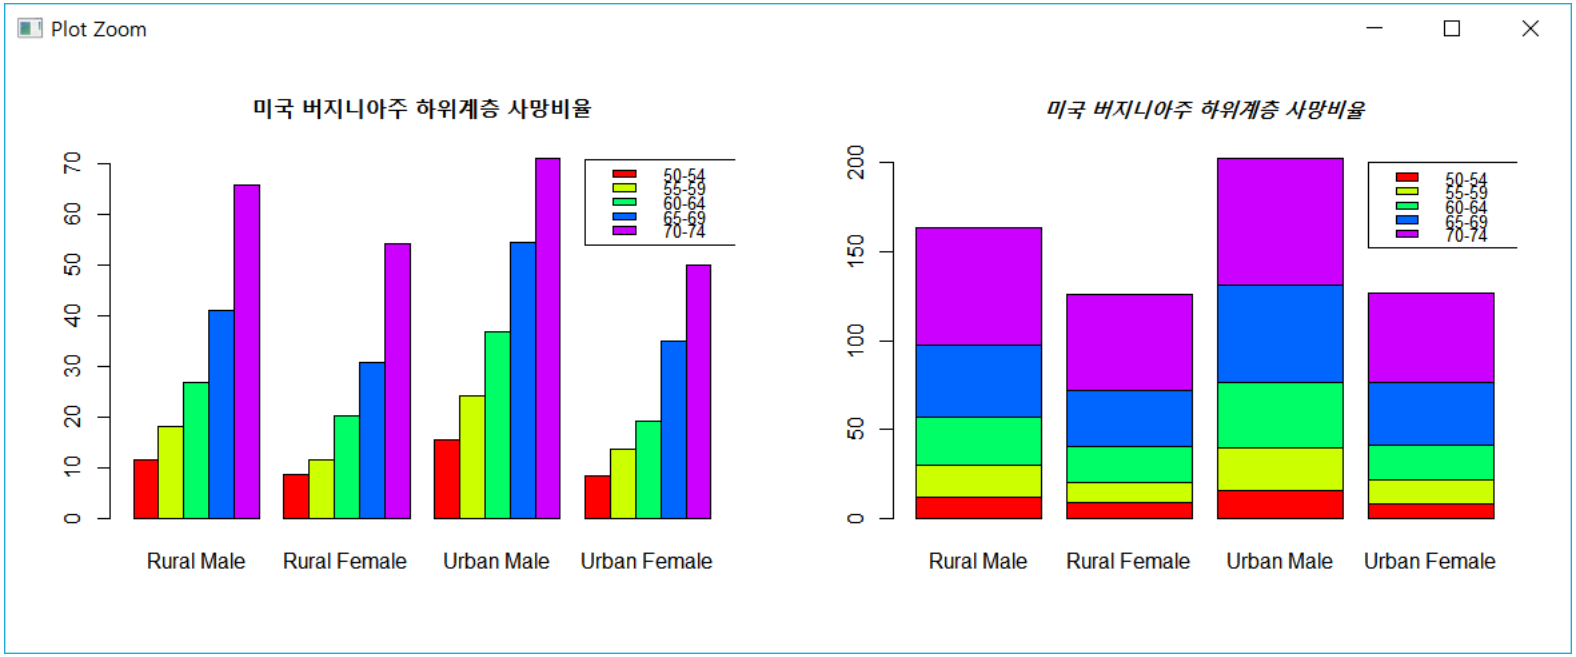

이산변수 시각화

② 점 차트 시각화

- dotchart() 형식 – 점 차트 그리기 함수

```
help(dotchart)

dotchart(x, labels = NULL, groups = NULL, gdata = NULL,
         cex = par("cex"), pt.cex = cex,
         pch = 21, gpch = 21, bg = par("bg"),
         color = par("fg"), gcolor = par("fg"), lcolor = "gray",
         xlim = range(x[is.finite(x)]),
         main = NULL, xlab = NULL, ylab = NULL, ...)
```

이산변수 시각화

② 점 차트 시각화

```
dotchart(chart_data, color=c("green","red"), lcolor="black",
         pch=1:2,  labels=names(chart_data), xlab="매출액",
         main="분기별 판매현황 점 차트 시각화", cex=1.2)
# col=9:10 -> BR(검정), AR(빨강)
# col=9:10 -> BR(검정), AR(빨강)
# lcolor="black" -> 구분선(line) 검정색
# pch=1:2 -> 점 모양 : 원(1), 삼각형(2), +(3)
# labels=names(Severity_Counts) : 점 레이블 표시
# cex=1.2 -> 1.2배 확대(character expension)
```

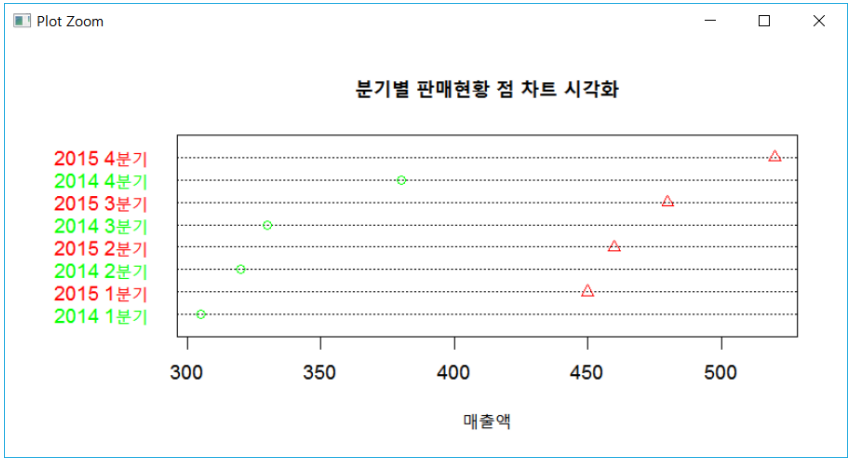

이산변수 시각화

③ 파이 차트 시각화

- pie() 형식 – 파일 차트 그리기 함수

```
help(pie)

pie(x, labels = names(x), edges = 200, radius = 0.8,
    clockwise = FALSE, init.angle = if(clockwise) 90 else 0,
    density = NULL, angle = 45, col = NULL, border = NULL,
    lty = NULL, main = NULL, ...)
```

이산변수 시각화

③ 파이 차트 시각화

```
pie(chart_data, labels = names(chart_data), border='blue', col=rainbow(8),
    cex=1.2)
title("2014~2015년도 분기별 매출현황")
```

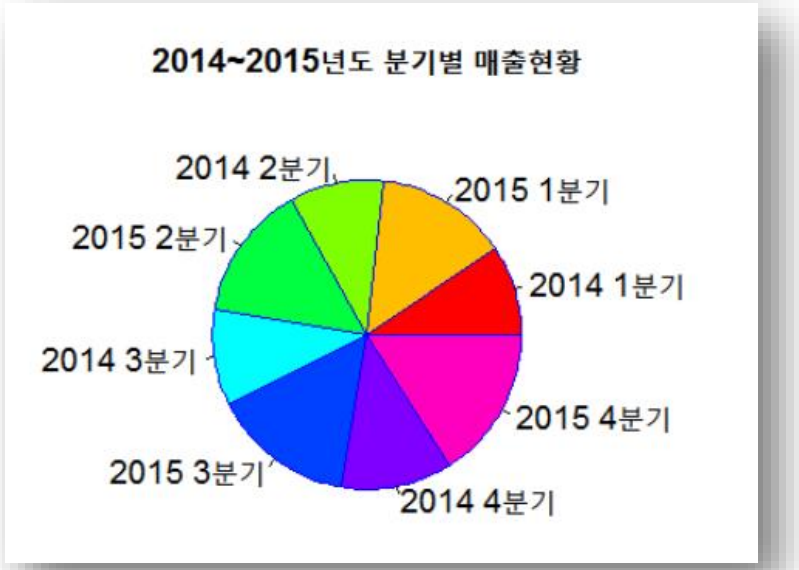

연속변수 시각화

2. 연속변수(Continuous quantitative data)

   - 시간, 길이 등과 같이 연속성을 가진 실수 단위 변수값

➢ 데이터 셋 가져오기

```
boxplot(VADeaths, range=0) # 상자 그래프 시각화
# range=0 : 최소값과 최대값을 점선으로 연결하는 역할
boxplot(VADeaths, range=0, notch=T)
# notch=T : 중위수 비교시 사용되는 옵션 <- 허리선
abline(h=37, lty=3, col="red") # 기준선 추가(lty=3 : 선 스타일-점선)
```

연속변수 시각화

① 상자 그래프 그래프 시각화

- ✓ 상자 그래프는 요약정보를 시각화한다.
- ✓ 데이터의 퍼짐 정도와 이상치 발견이 목적

```
> summary(VADeaths)
  Rural Male      Rural Female     Urban Male      Urban Female
 Min.   :11.70   Min.   : 8.70   Min.   :15.40   Min.   : 8.40
 1st Qu.:18.10   1st Qu.:11.70   1st Qu.:24.30   1st Qu.:13.60
 Median :26.90   Median :20.30   Median :37.00   Median :19.30
 Mean   :32.74   Mean   :25.18   Mean   :40.48   Mean   :25.28
 3rd Qu.:41.00   3rd Qu.:30.90   3rd Qu.:54.60   3rd Qu.:35.10
 Max.   :66.00   Max.   :54.30   Max.   :71.10   Max.   :50.00
```

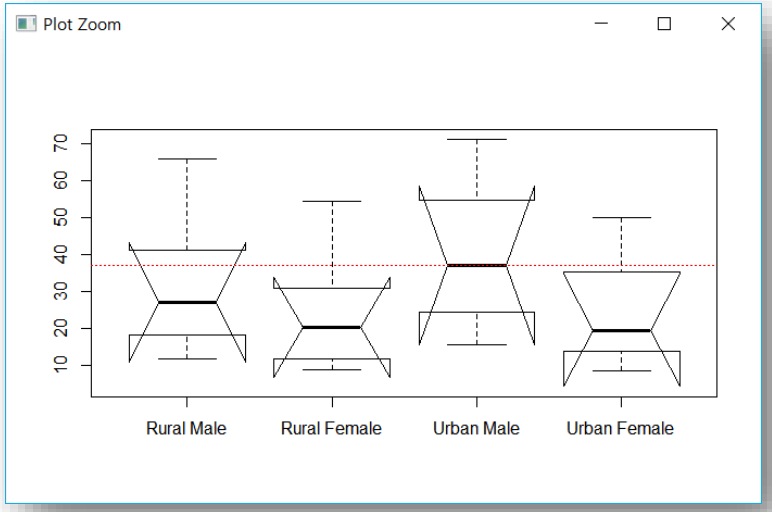

연속변수 시각화

② 히스토그램 시각화

```
# 데이터 셋 가져오기
data(iris) # iris 데이터 셋 가져오기
names(iris) #"child"   "parent"
str(iris) # 928    2
head(iris)

# Sepal.Length Sepal.Width Petal.Length Petal.Width Species

summary(iris$Sepal.Length)
summary(iris$Sepal.Width)
```

연속변수 시각화

➢ 히스토그램 시각화(parent)

```
hist(iris$Sepal.Width, xlab="iris$Sepal.Width", col="mistyrose",
     main="iris 꽃받침 넓이 histogram", xlim=c(2.0, 4.5))
# col="mistyrose" : 색상(흐릿한 장미) 적용
# breaks="FD" : Freedman-Diaconis, 구간 너비
# xlab : x축 이름, main : 제목, xlim : x축 범위
```

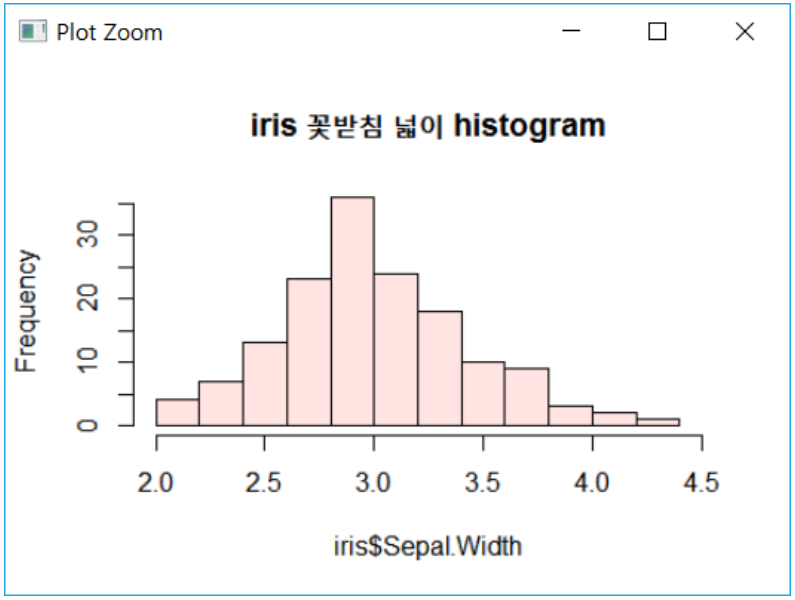

연속변수 시각화

- 히스토그램 시각화(child)

```
par(mfrow=c(1,2))
hist(iris$Sepal.Width, xlab="iris$Sepal.Width", col="green",
     main="iris 꽃받침 넓이 histogram", xlim=c(2.0, 4.5))
# 확률 밀도로 히스토그램 그리기 - 연속형변수의 확률
hist(iris$Sepal.Width, xlab="iris$Sepal.Width", col="mistyrose", freq = F,
     main="iris 꽃받침 넓이 histogram", xlim=c(2.0, 4.5))
# 밀도를 기준으로 line을 그려준다.
lines(density(iris$Sepal.Width), col="red")
```

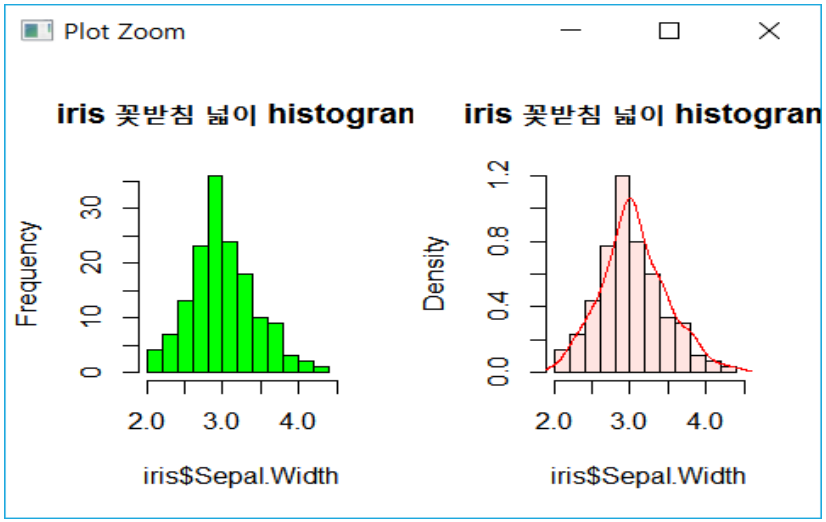

연속변수 시각화

- 정규분포 곡선 추정

```
par(mfrow=c(1,1))
hist(iris$Sepal.Width, xlab="iris$Sepal.Width", col="mistyrose", freq = F,
     main="iris 꽃받침 넓이 histogram", xlim=c(2.0, 4.5))
# 밀도를 기준으로 line을 그려준다.
lines(density(iris$Sepal.Width), col="red")
curve(dnorm(x, mean=mean(iris$Sepal.Width), sd=sd(iris$Sepal.Width)), col="blue",
      add = T)
```

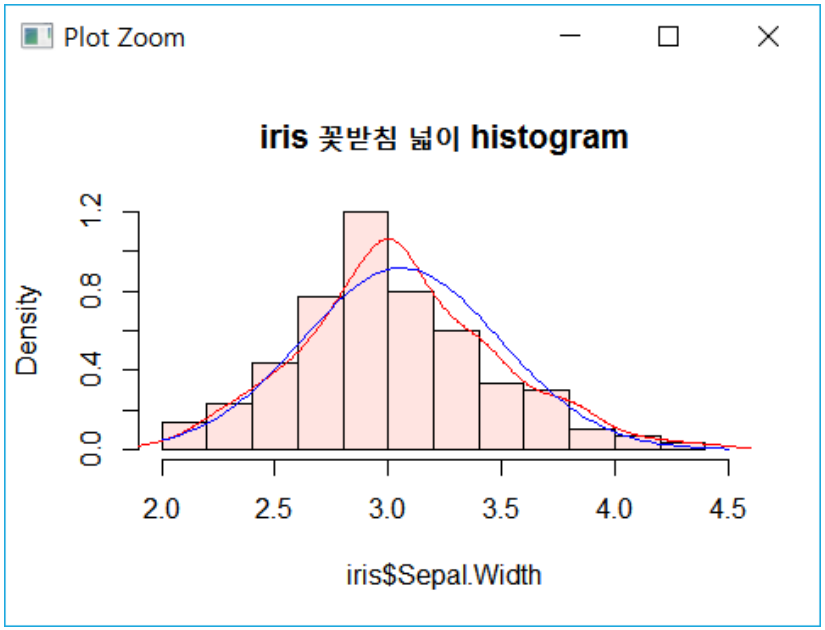

연속변수 시각화

③ 산점도 시각화

```
price<- runif(10, min=1, max=100) # 1~100사이 10개 난수 발생
price #price <-c(1:10)
par(mfrow=c(2,2)) # 2행 2열 차트 그리기
plot(price, type="l") # 유형 : 실선
plot(price, type="o") # 유형 : 원형과 실선(원형 통과)
plot(price, type="h") # 직선
plot(price, type="s") # 꺾은선
```

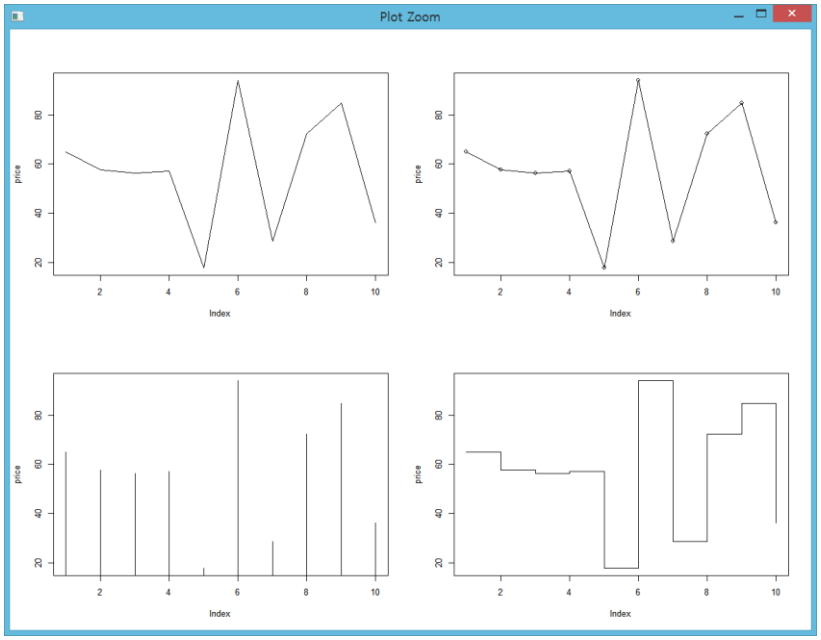

연속변수 시각화

plot() 함수 속성 : pch : 연결점 문자타입-> plotting characher-번호(1~30)

```
plot(price, type="o", pch=5) # 빈 사각형

plot(price, type="o", pch=15)# 채워진 마름모

plot(price, type="o", pch=20, col="blue") #color 지정

plot(price, type="o", pch=20, col="orange", cex=1.5) #character expension(확대)

plot(price, type="o", pch=20, col="green", cex=2.0, lwd=3) #lwd : line width
```

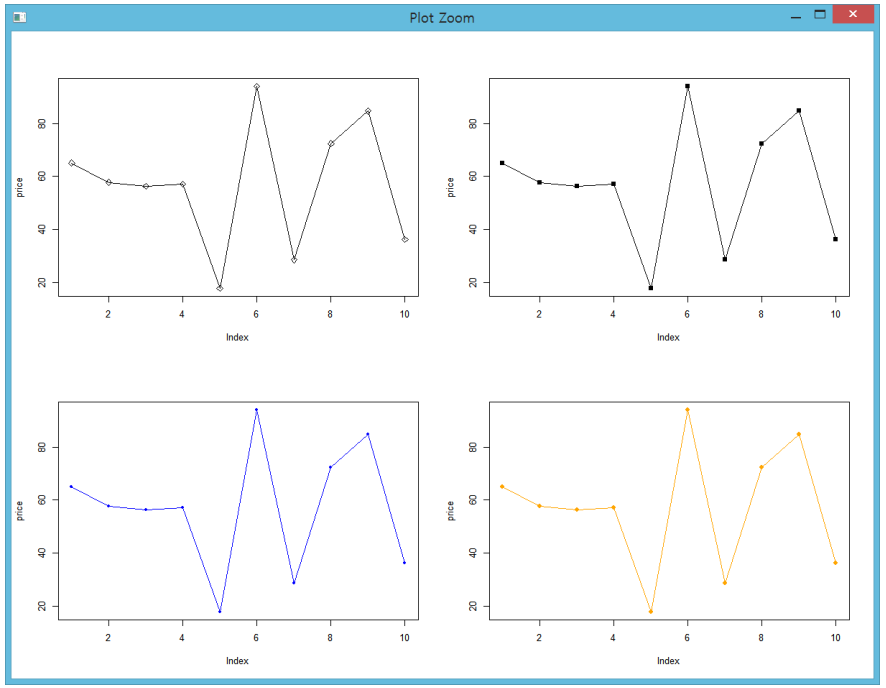

연속변수 시각화

- 산점도와 회귀선 시각화

```
# galton 데이터 셋을 이용한 변수 간 상관관계
# parent와 child 변수 대상
par(mfrow=c(1,1))
plot(child~parent, data=galton)
out = lm(child~parent, data=galton)
abline(out, col="red")
```

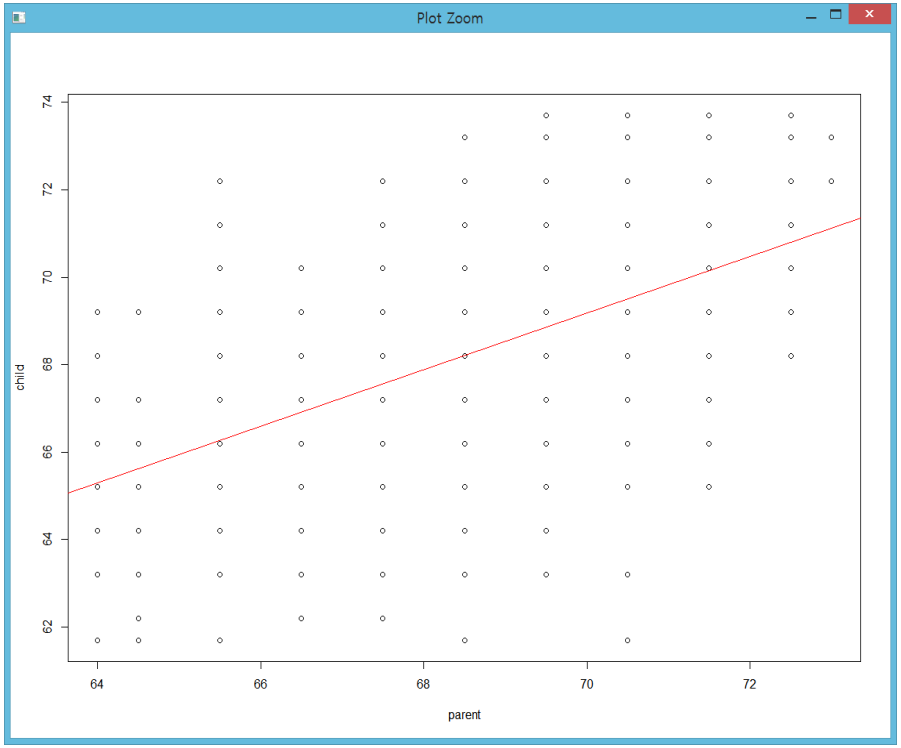

동일데이터가 겹친 경우 시각화 표현

3. 중복 데이터 시각화

- 시간, 길이 등과 같이 연속성을 가진 실수 단위 변수값

1) 데이터프레임으로 변환 : 컬럼 단위의 데이터 활용을 위해서

```
freqData <- as.data.frame(table(galton$child, galton$parent))
freqData # Var1 Var2 Freq(중복 수)
str(freqData) # 154 obs(928 관측치가 중복 제외한 154개 관측치 생성 )
names(freqData)=c("child","parent", "freq") # 컬럼에 이름 지정
```

2) 프레임 -> 벡터 -> 수치데이터변환, cex : 빈도수에 0.15 곱(가중치 적)

```
parent <- as.numeric(as.vector(freqData$parent))
child <- as.numeric(as.vector(freqData$child))
plot(child~parent, pch=21, col="blue", bg="green",
     cex=0.15*freqData$freq, xlab="parent", ylab="child")
```

연속변수 시각화

- 빈도수를 적용한 가중치 적용

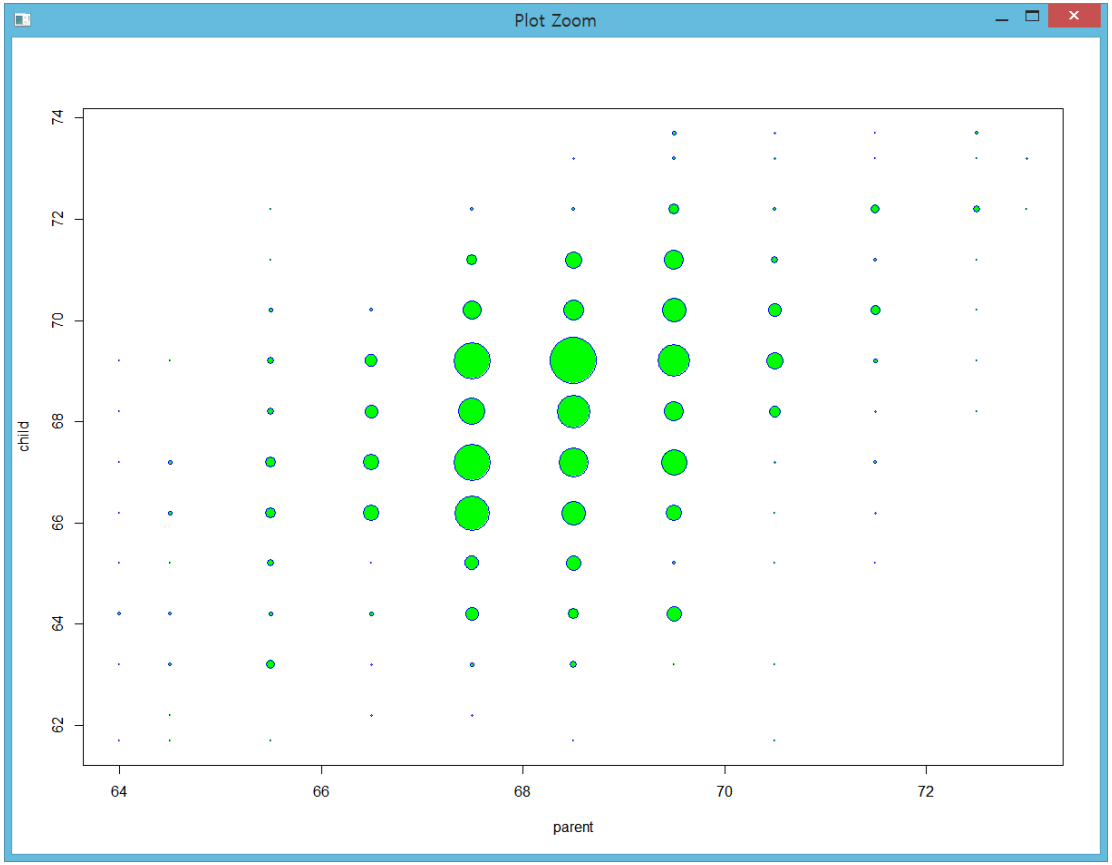

부모와 자식 간 변수 비교

변수간 비교 시각화 결과

4. 변수간 비교 시각화 결과

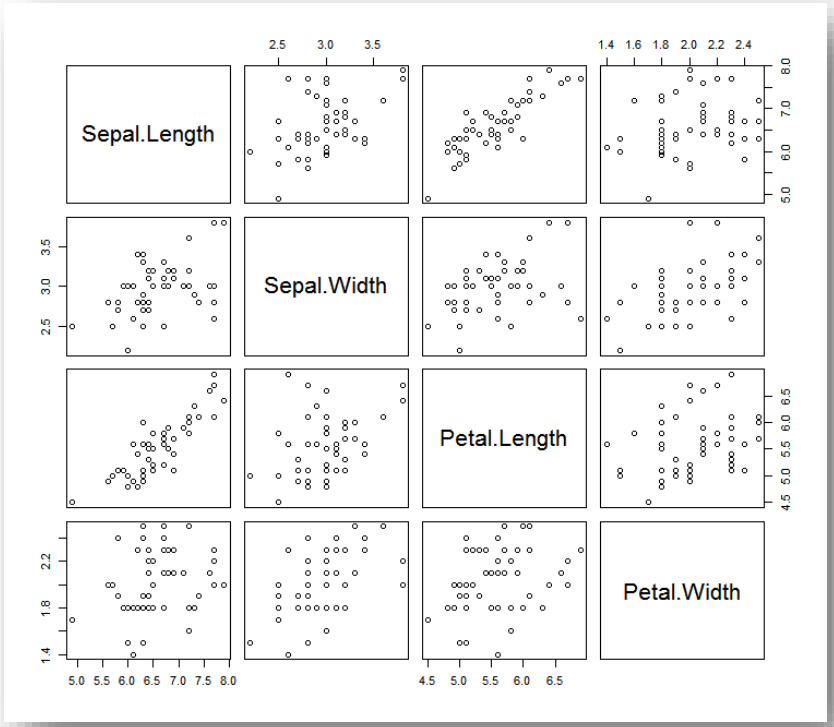

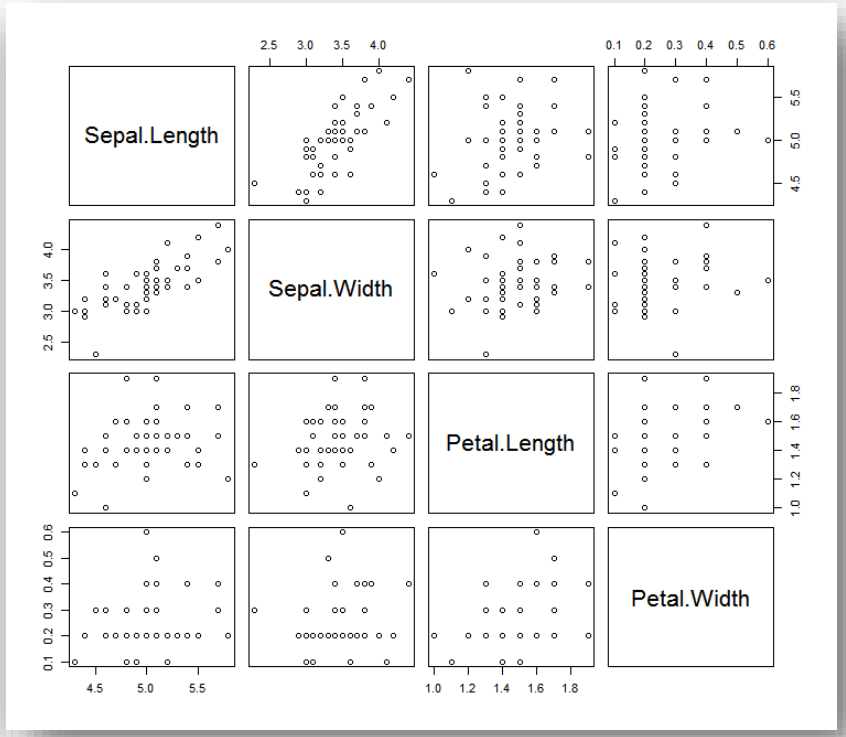

변수간 비교 시각화 결과

plot(iris) # iris 데이터를 대상으로 제공되는 모든 차트 그려줌

plot(iris[, -5], col=iris[,5]) # 5번 컬럼 제거, 색지정으로 사용

title(main="다양한 차트")

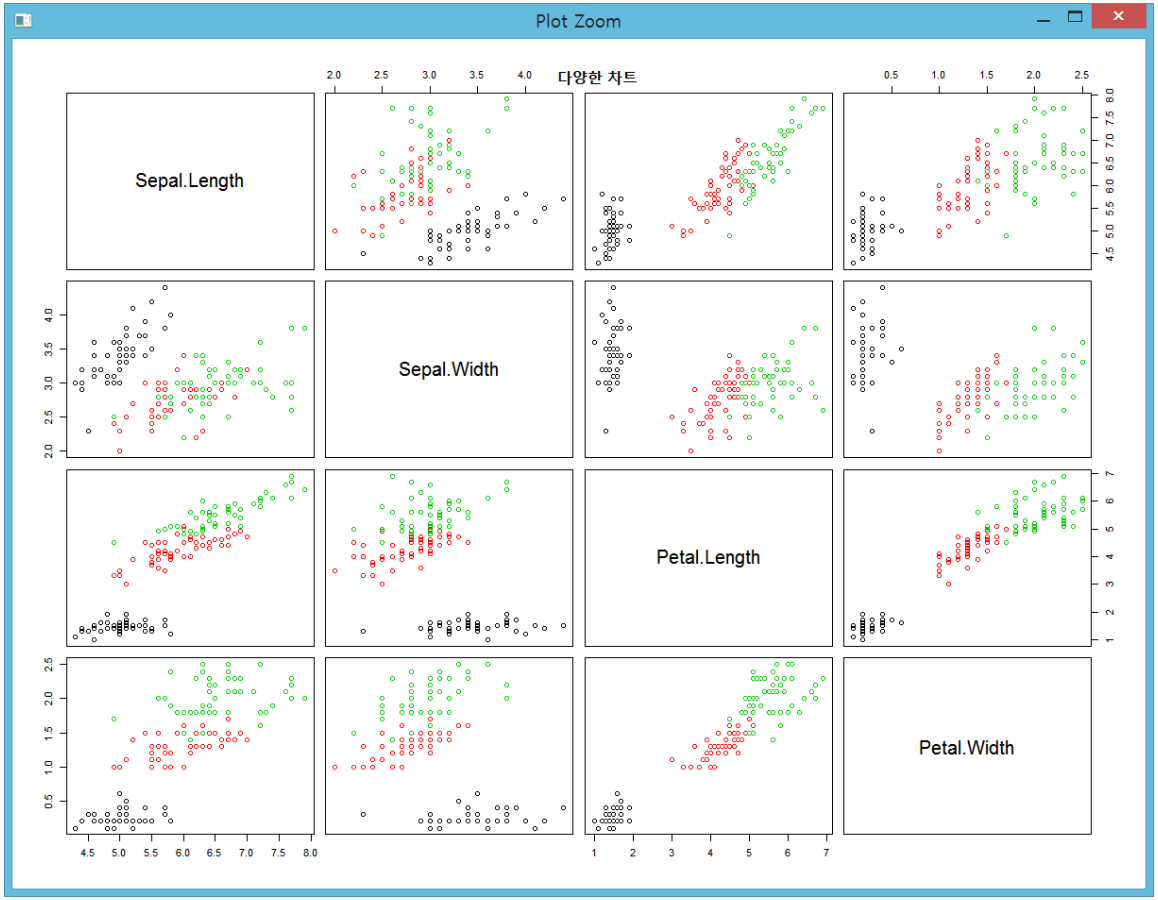

차트 결과 파일 저장

5. 파일로 차트 저장하기

```
setwd("C:/workspaces/Rwork/data") # 폴더 지정
jpeg("iris.jpg", width=720, height=480) # 픽셀 지정 가능
plot(iris$Sepal.Length, iris$Petal.Length, col=iris$Species)
title(main="iris 데이터 테이블 산포도 차트")
dev.off() # 장치 종료

# "C:/workspaces/Rwork/data" <- 이미지 파일 확인
```

6. 칼럼의 속성에 따른 시각화 도구 분류

- 칼럼 수와 자료의 형태에 따라서 시각화 도구가 달라진다.

칼럼 특성			시각화 도구
칼럼 수	수치형	범주형	
1	1		hist, plot, barplot
1		1	pie, barplot
2	2		plot, abline, boxplot
3	3		scatterplot3d
n	n	n	pairs

칼럼의 속성에 따른 시각화 도구 분류

- scatterplot3d

```
setwd("C:/workspaces/Rwork/data") # 폴더 지정

jpeg("iris.jpg", width=720, height=480) # 픽셀 지정 가능

plot(iris$Sepal.Length, iris$Petal.Length, col=iris$Species)

title(main="iris 데이터 테이블 산포도 차트")

dev.off() # 장치 종료

# "C:/workspaces/Rwork/data" <- 이미지 파일 확인
```