고급 시각화 분석

lattice 패키지

- Lattice Plotting System 특징
  - ✓ 다차원 데이터를 사용할 경우, 한 번에 여러 개의 plot 생성 가능
  - ✓ 높은 밀도의 plot를 효과적으로 그려준다.
  - ✓ 직교형태의 그래픽(Trellis graphic) 생성
  - ✓ lattice package 제공 함수
    - histogram(), densityplot(), barchart(), dotplot(), xyplot(), equal.count(), cloud()

lattice 패키지

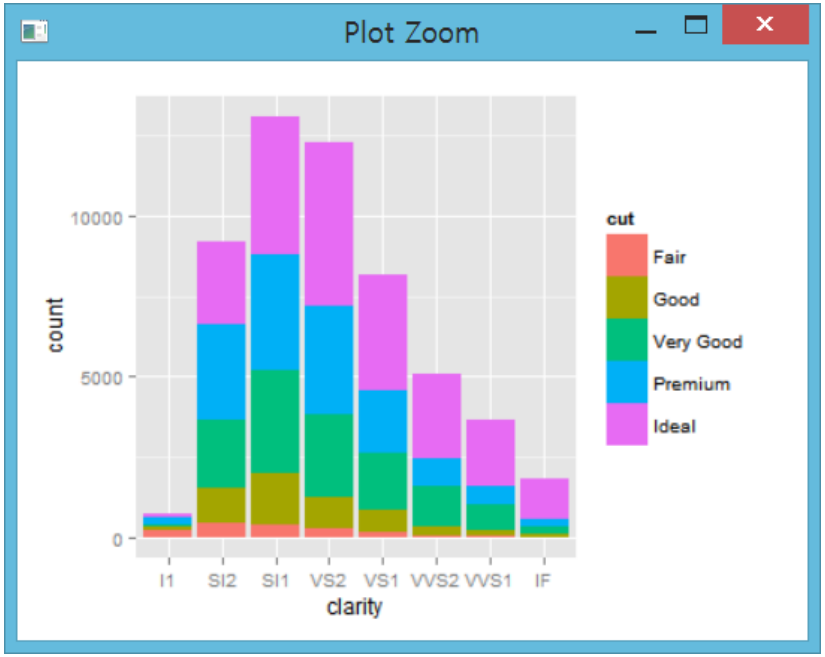
Plot Zoom
10000
5000
0
count
I1
SI2
SI1
VS2
VS1
VVS2
VVS1
IF
clarity
cut
Fair
Good
Very Good
Premium
Ideal

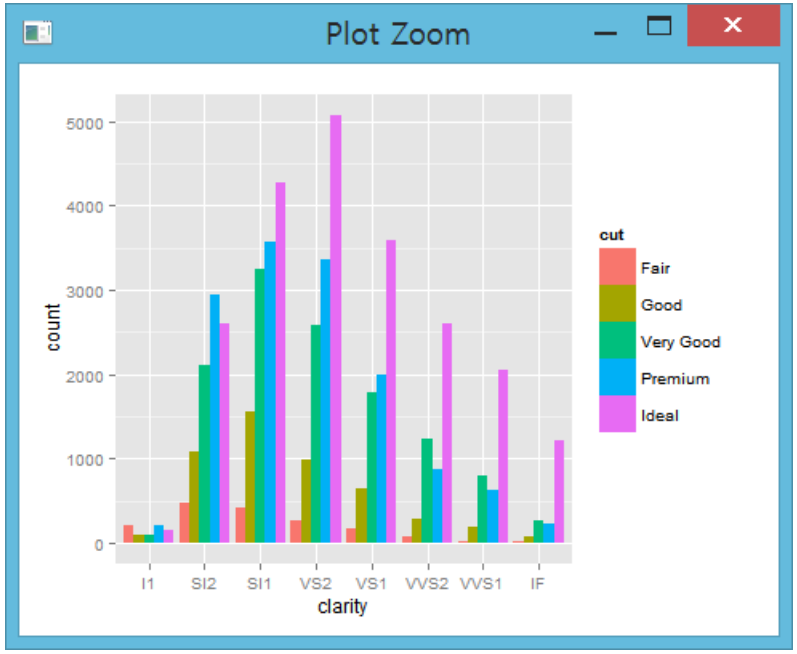
Plot Zoom
5000
4000
3000
2000
1000
0
count
I1
SI2
SI1
VS2
VS1
VVS2
VVS1
IF
clarity
cut
Fair
Good
Very Good
Premium
Ideal

lattice 패키지

- lattice package 및 데이터 셋 설치

```
install.packages("lattice")
library(lattice)
install.packages("mlmRev")
library(mlmRev)
data(Chem97)
str(Chem97) # data.frame':  31022 obs. of  8 variables:
head(Chem97,30) # 앞쪽 30개 레코드
Chem97
######### Chem97 데이터 셋 설명 ###########
# - mlmRev 패키지에서 제공
# - 1997년 영국 2,280개 학교 31,022명을 대상으로 A레벨(대학시험) 화학점수
# - lea 변수 : Local Education Authority(지방교육청:1~131)
# - score 변수 : A레벨 화학점수(0,2,4,6,8,10)
# - gender 변수 : 성별
# - age : 18.5세 기준 월수(범위: -6~+5)
# - gcsescore 변수 : 고등학교 재학중에 치루는 큰 시험(GCSE : 중등교수학능력정 인증시험)
# - GCSE : General Certificate of Secondary Education)
########################################
```

lattice 패키지

1. histogram(~x축, dataframe)

```
histogram(~gcsescore, data=Chem97)
# gcsescore변수를 대상으로 백분율 적용 히스토그램

# score를 조건변수로 지정(score 단위 적용)
histogram(~gcsescore | score, data=Chem97)
histogram(~gcsescore | factor(score), data=Chem97)
# score를 요인으로 적용

##############################################
# 요인(factor) 수준은 그래픽 출력에 영향을 미친다.
# 예를들면, score를 x축에 대입할 경우 score가 출력되지만,
# factor로 변환된 score를 x축에 대입하면, 요인수준이
# 순서로 적용된다.(0,2,4,6,8,10)
##############################################
```

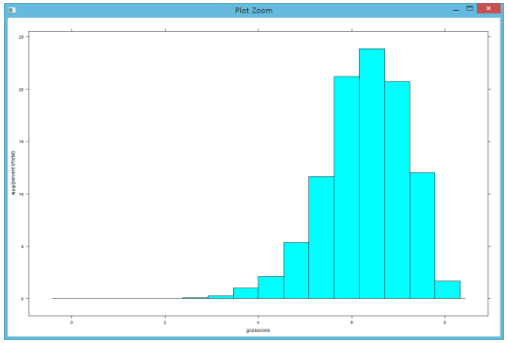

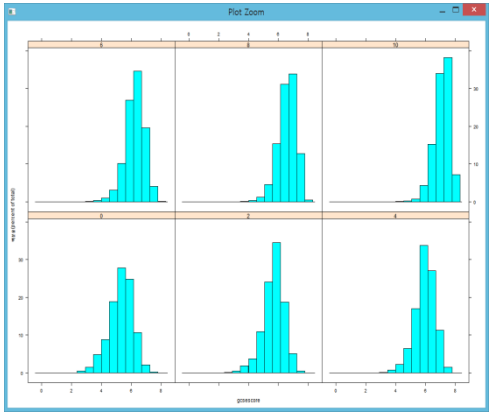

lattice 패키지

score를 조건변수로 지정

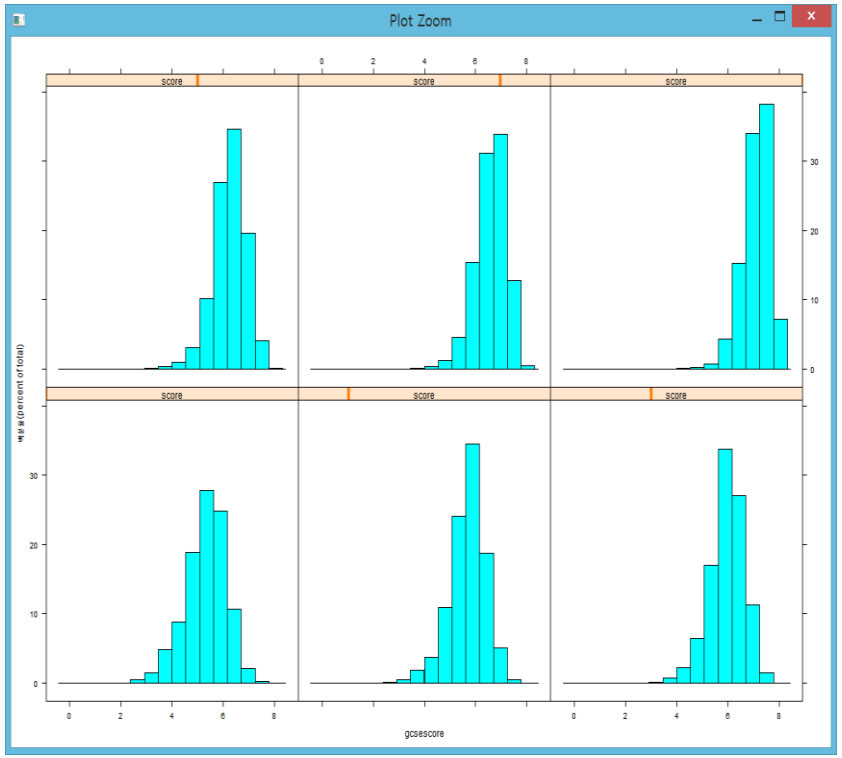

score를 요인으로 적용

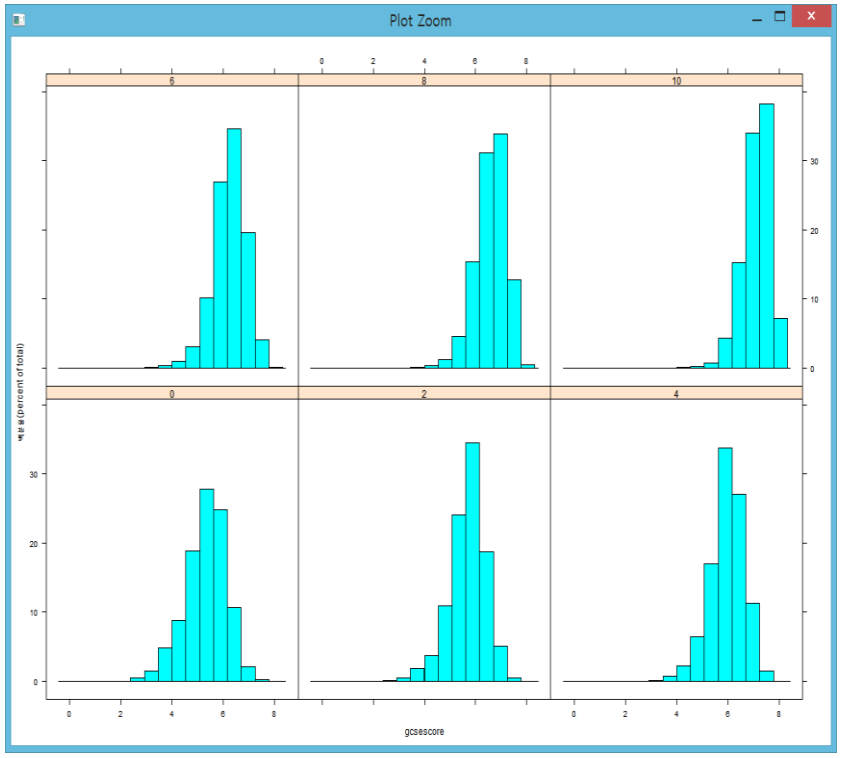

lattice 패키지

2. densityplot(~x축 | 조건, dataframe, groups=변수)

```
densityplot(~gcsescore | factor(score), data=Chem97,
                groups = gender, plot.points=F, auto.key = T)
# 밀도 점 표시 여부 : plot.points=F
# 범례 표시 : auto.key=T
# 성별로 GCSE점수를 score 단위로 밀도 플로팅
```

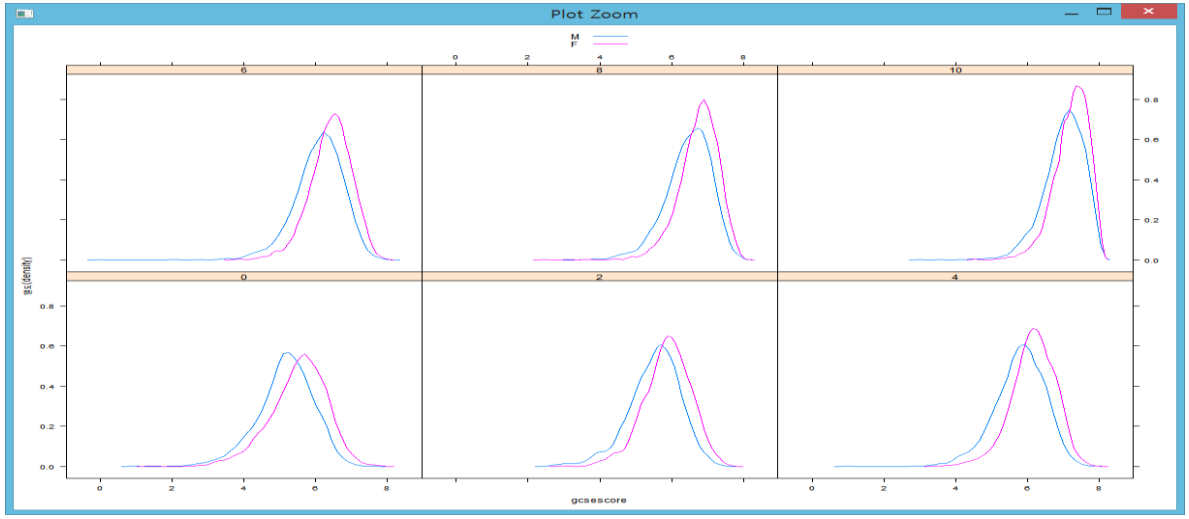

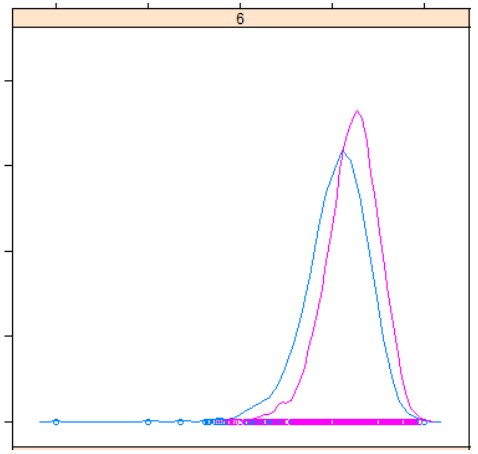

plot.points=T

lattice 패키지

- 통계처리를 위한 데이터 형식 변경(matrix -> data.frame/table)

1) Data set가져오기

```
data(VADeaths)
###### VADeaths 데이터셋 설명 ##############
# 1941년 미국 버지니아주의 하위계층 사망비율
# Rural Male(시골출신 남자), Urban Male(도시출신 남자)
# Rural Female(시골출신 여자), Urban Female(도시출신 여자)
##########################################

VADeaths
#       Rural Male Rural Female Urban Male Urban Female
#50-54       11.7          8.7       15.4          8.4
#55-59       18.1         11.7       24.3         13.6
#60-64       26.9         20.3       37.0         19.3
#65-69       41.0         30.9       54.6         35.1
#70-74       66.0         54.3       71.1         50.0

# VADeaths 데이터 셋 특성 보기
class(VADeaths) # matrix
mode(VADeaths) # numeric
```

lattice 패키지

- 통계처리를 위한 데이터 형식 변경

  2) 데이터 형식 변경

```
# matrix -> data.frame 변환
df <- as.data.frame(VADeaths)
str(df) # 'data.frame':  5 obs. of  4 variables:
class(df) # data.frame 생성

# matrix -> table 변환(행열 구조 변환)
dft <- as.data.frame.table(VADeaths)
str(dft) # 'data.frame':  20 obs. of  3 variables:
dft # 1열 기준으로 table 생성
```

```
#    Var1         Var2     Freq
#1   50-54    Rural Male 11.7
#2   55-59    Rural Male 18.1
#    :
#19 65-69 Urban Female 35.1
#20 70-74 Urban Female 50.0
```

lattice 패키지

- matrix -> data.frame

	Rural Male	Rural Female	Urban Male	Urban Female
50-54	11.7	8.7	15.4	8.4
55-59	18.1	11.7	24.3	13.6
60-64	26.9	20.3	37.0	19.3
65-69	41.0	30.9	54.6	35.1
70-74	66.0	54.3	71.1	50.0

- matrix->data.frame.table

	Var1	Var2	Freq
1	50-54	Rural	Male 11.7
2	55-59	Rural	Male 18.1
3	60-64	Rural	Male 26.9
4	65-69	Rural	Male 41.0
5	70-74	Rural	Male 66.0
6	50-54	Rural	Female 8.7
7	55-59	Rural	Female 11.7
8	60-64	Rural	Female 20.3
9	65-69	Rural	Female 30.9
10	70-74	Rural	Female 54.3
11	50-54	Urban	Male 15.4
12	55-59	Urban	Male 24.3
13	60-64	Urban	Male 37.0
14	65-69	Urban	Male 54.6
15	70-74	Urban	Male 71.1
16	50-54	Urban	Female 8.4
17	55-59	Urban	Female 13.6
18	60-64	Urban	Female 19.3
19	65-69	Urban	Female 35.1
20	70-74	Urban	Female 50.0

lattice 패키지

3. barchart(y~x | 조건, dataframe, layout)

barchart(Var1 ~ Freq | Var2, data=dft, layout=c(4,1))

Var2변수값을 기준으로 가로막대차트 플로팅

barchart(Var1 ~ Freq | Var2, data=dft, layout=c(4,1), origin=0)

origin=0 : 0부터 시작

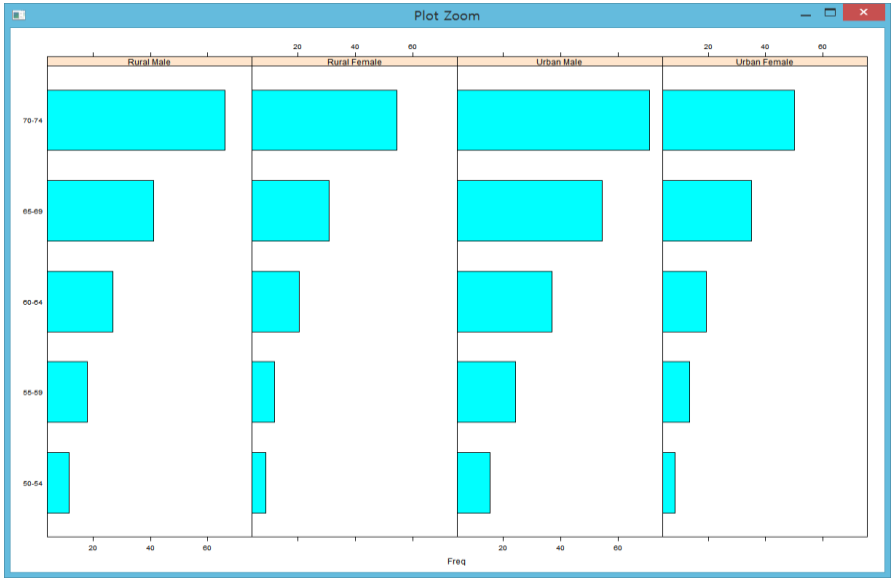

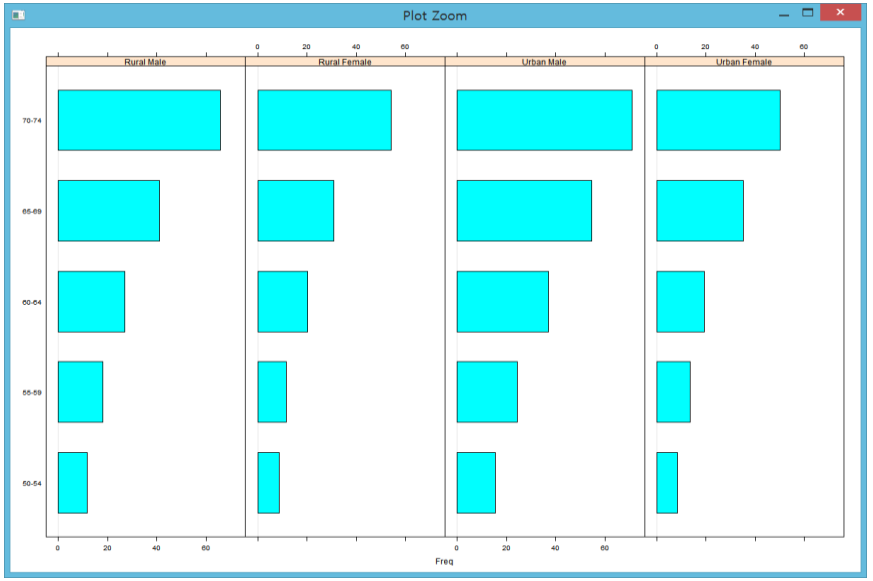

lattice 패키지

4. dotplot(y~x | 조건 , dataframe, layout)

dotplot(Var1 ~ Freq | Var2 , dft)
dotplot(Var1 ~ Freq | Var2 , dft, layout=c(4,1)) # 1행 4열

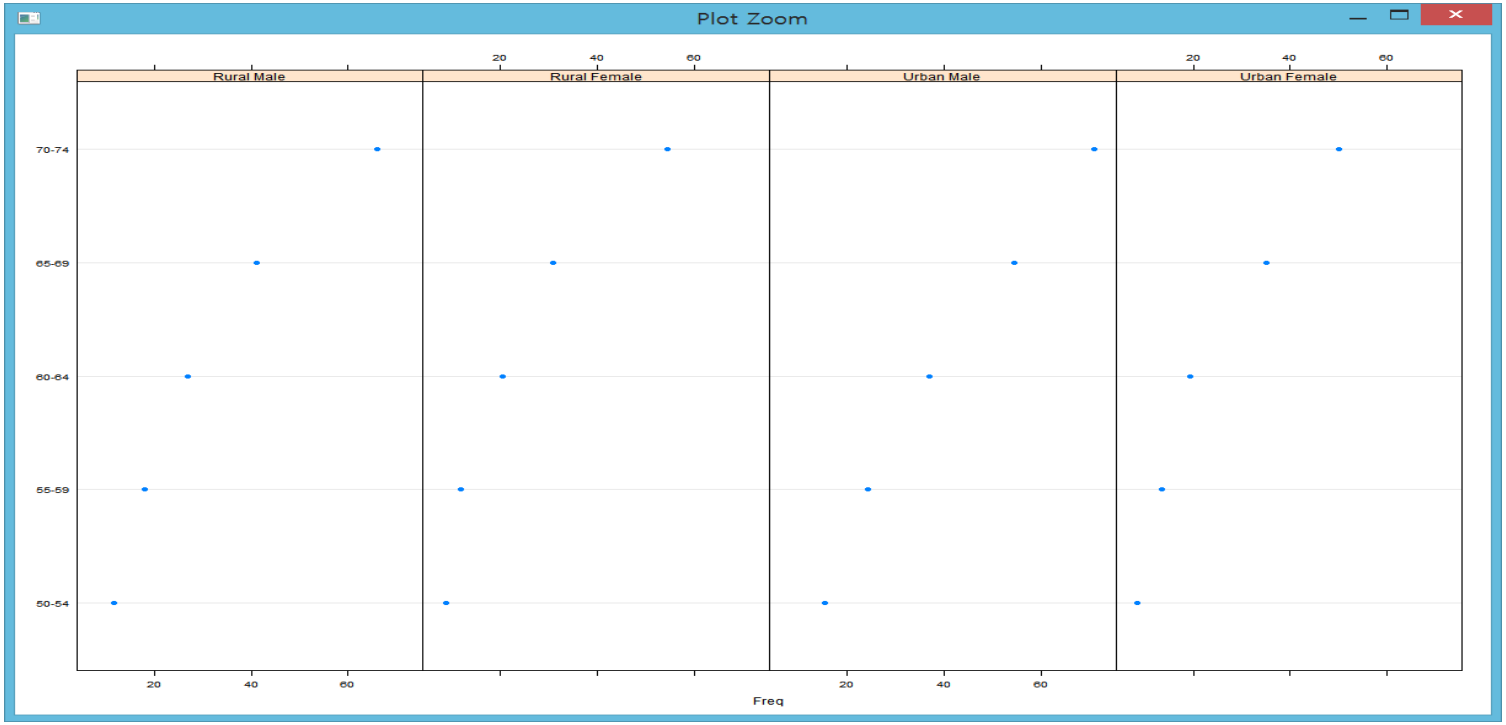

lattice 패키지

```
# Var2변수를 그룹화하여 점을 연결하여 플로팅
dotplot(Var1 ~ Freq, data=dft, groups=Var2, type="o",
        auto.key=list(space="right", points=T, lines=T))
# 산점도 타입 : type="o" : 원형에 실선 통과
# 범례 : auto.key=list(배치위치, 점 추가, 선 추가)
```

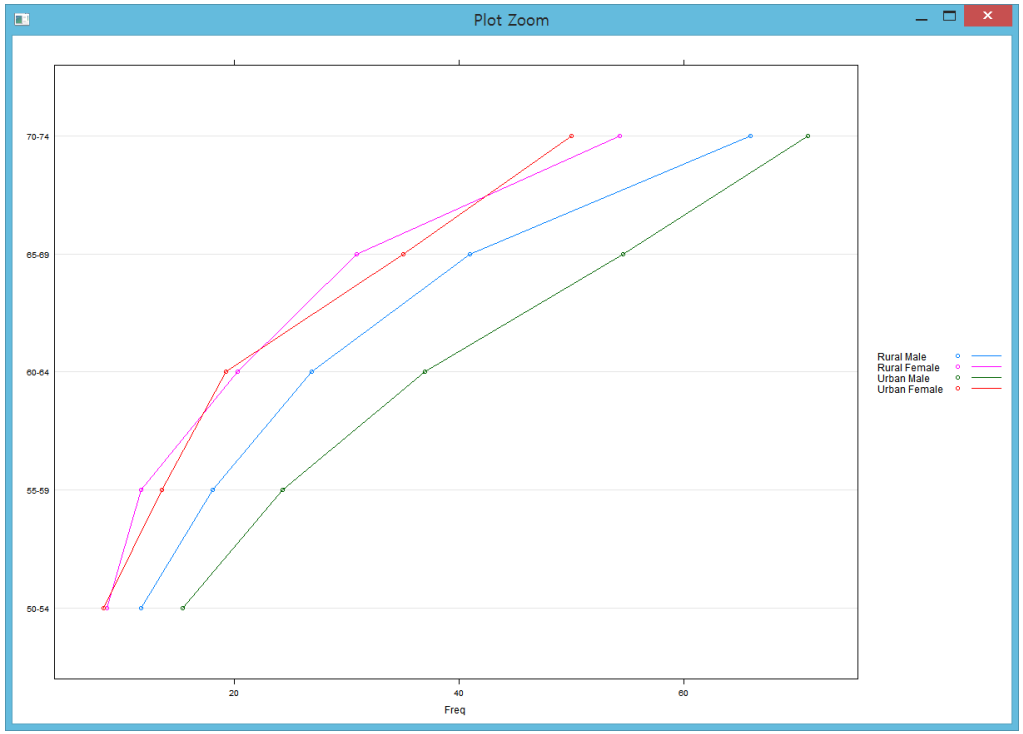

lattice 패키지

5. xyplot(y축~x축, dataframe or list)

- Data set 가져오기

```
library(datasets)
str(airquality) # datasets의 airqulity 테이터 활용

###### airquality 데이터셋 설명 ##############
# datasets 패키지에서 제공
# 뉴욕시의 대기오염에 관한 데이터셋
# data.frame ' :  153 obs. of  6 variables:
# 주요변수 : Ozone(오존), Solar.R(태양열), Wind(바람), Temp(온도), Month(월:5~9),
#                Day(일:1~31)
########################################

airquality # Ozone Solar.R Wind Temp Month(5~9) Day
```

lattice 패키지

5. xyplot(y축~x축, dataframe or list)

xyplot(Ozone ~ Wind, data=airquality) # airquality의 Ozone(y),Wind(x)

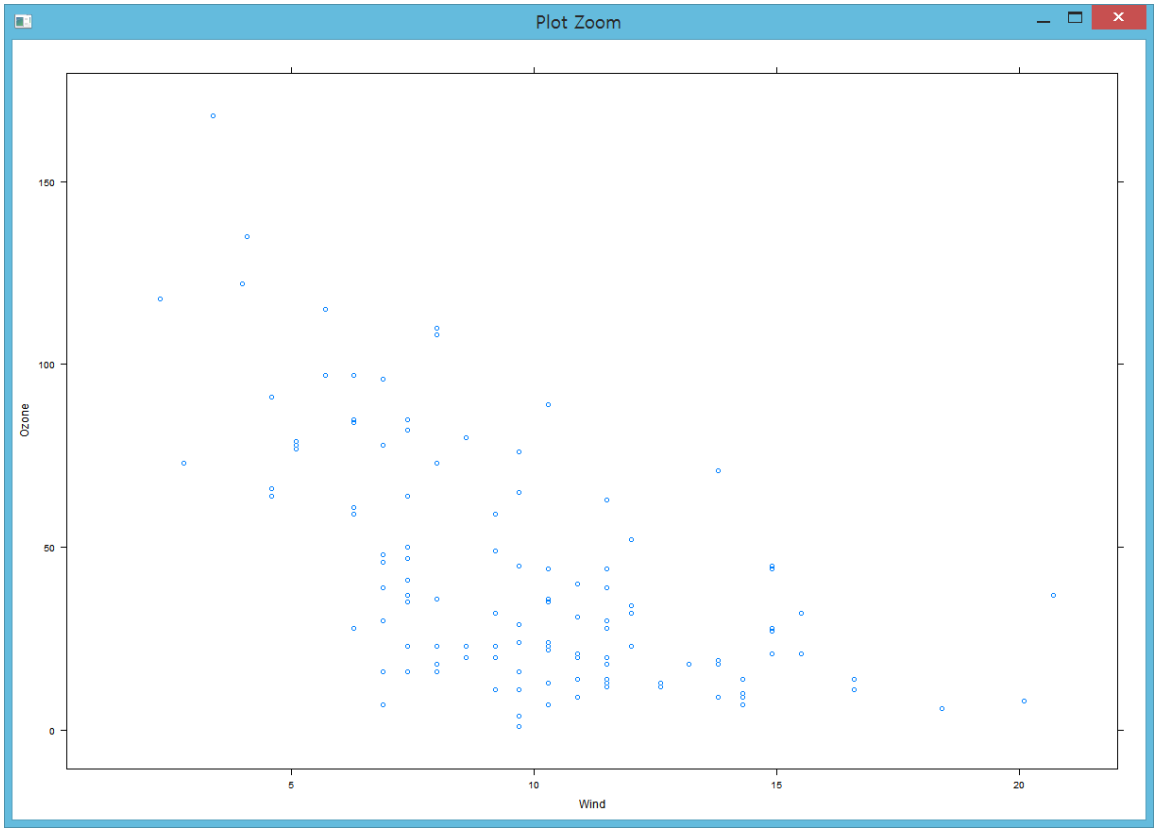

lattice 패키지

```
# airquality 데이터셋의 Month(5~9)변수 기준(월별) 플로팅
xyplot(Ozone ~ Wind | Month, data=airquality) # 2행3컬럼
# default -> layout=c(3,2)
xyplot(Ozone ~ Wind | Month, data=airquality, layout=c(5,1))
# 5컬럼으로 플로팅 - 컬럼 제목 : Month
```

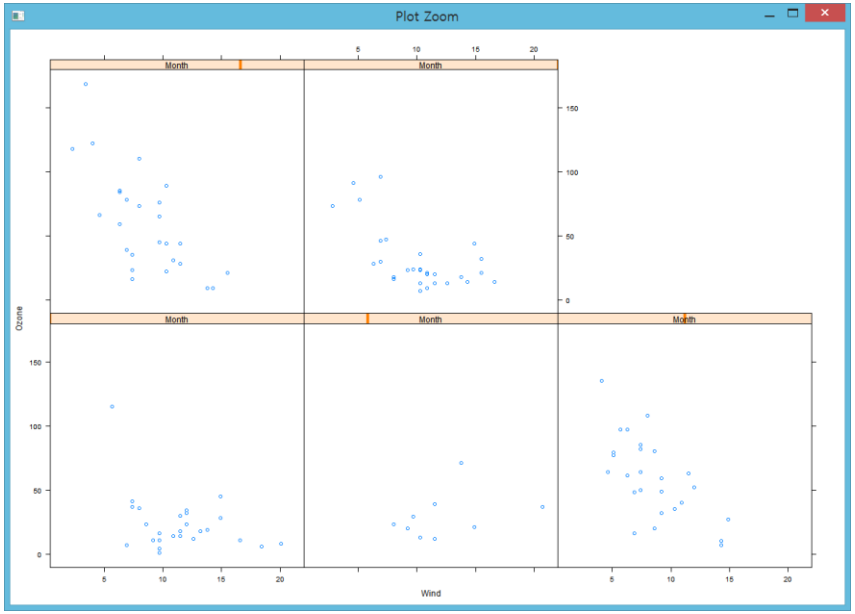

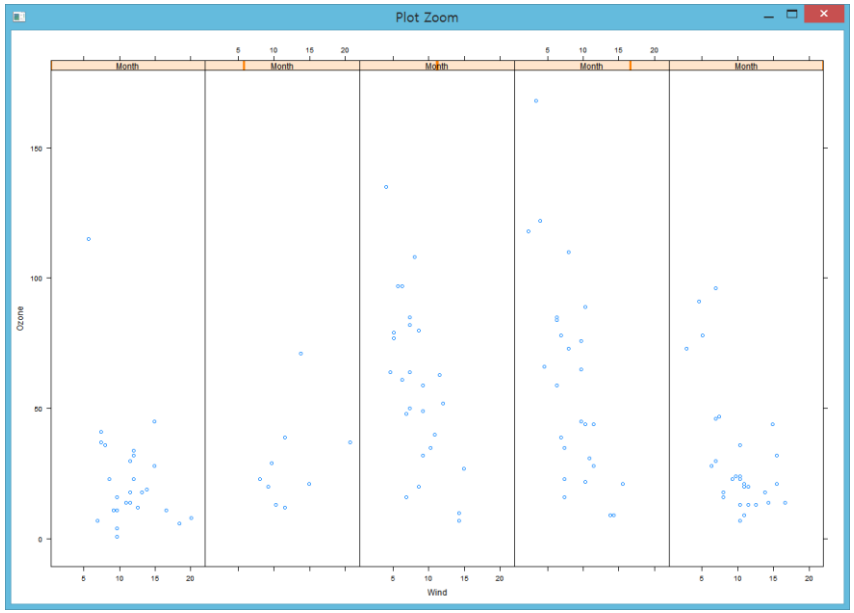

lattice 패키지

```
# Month를 int 타입에서 factor 데이터 타입으로 변경
convert <- transform(airquality, Month=factor(Month))
str(convert) # Month 변수의 Factor값 확인
# $ Month  : Factor w/ 5 levels "5","6","7","8"
# Month의 factor 타입을 data에 적용
xyplot(Ozone ~ Wind | Month, data=convert, layout=c(5,1))
# 컬럼 제목 : Month 값으로 출력
```

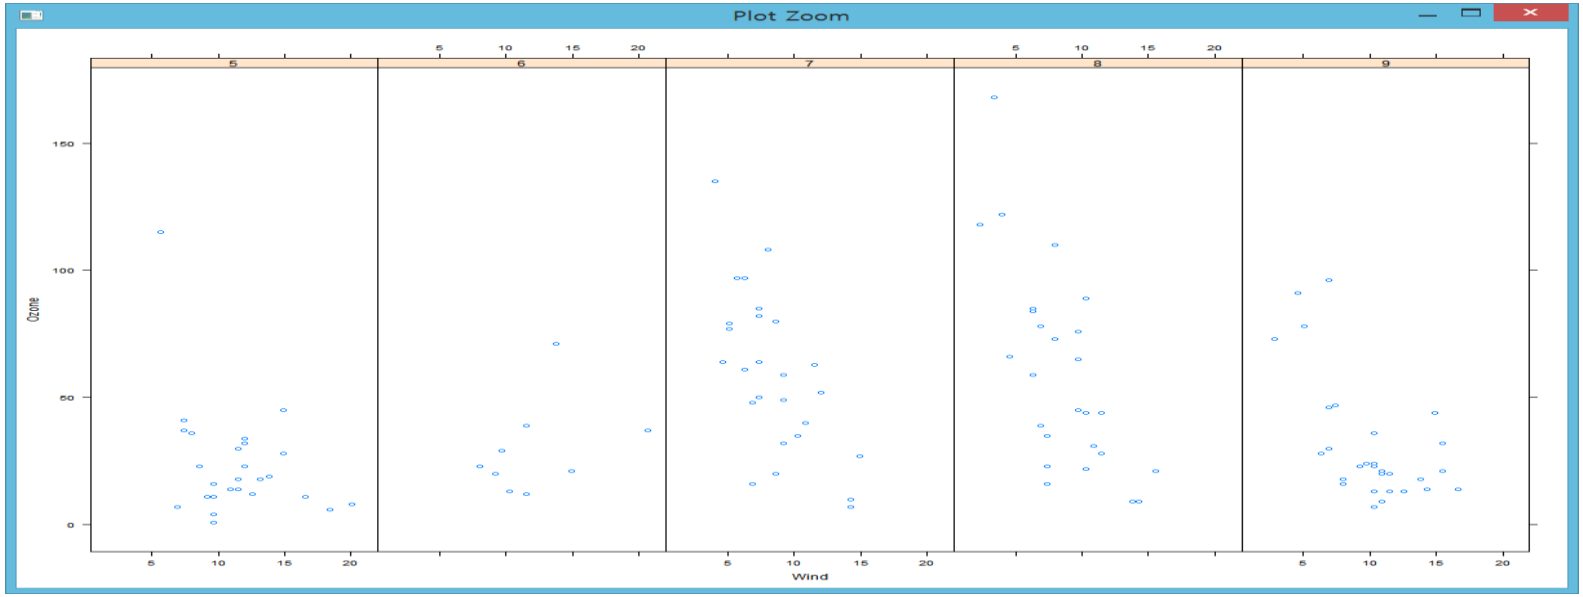

lattice 패키지

- Data set 가져오기

```
head(quakes)
str(quakes) # 'data.frame':  1000 obs. of  5 variables:
# lat, long, depth, mag, stations

############### quakes 데이터셋 설명 ############################
#   R에서 제공하는 기존 데이터셋
#  1964년 이후 피지(태평양) 근처에 발생한 지진 사건
#   주요 변수 : lat:위도,long:경도,depth:깊이(km), mag:리히터규모,stations
#################################################################
```

lattice 패키지

```
xyplot(lat~long, data=quakes, pch=".") # 지진발생 위치(위도와 경로)
# 그래프를 변수에 저장
tplot<-xyplot(lat~long, data=quakes, pch=".")
# 그래프에 제목 추가
tplot2<-update(tplot, main="1964년 이후 태평양에서 발생한 지진위치")
print(tplot2)
```

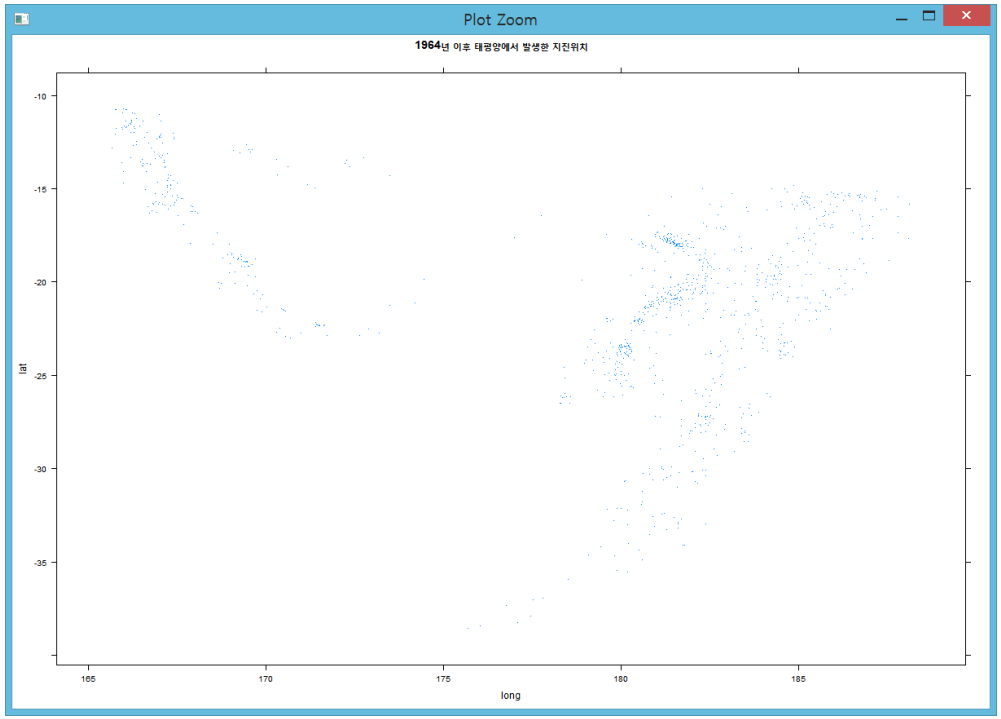

lattice 패키지

6. equal.count(변수, number=n, overlap=n)

```
# 변수값을 대상으로 지정한 영역 만큼 수량 카운터
numgroup<- equal.count(1:100, number=3, overlap=0)
# 1~100 데이터를 대상으로 겹치지 않게 3개 영역으로 구분 영역별 count 구하기
numgroup
#Intervals:
#    min    max count
#1   0.5   33.5     33
#2  33.5   67.5     34
#3  67.5  100.5     33
```

lattice 패키지

```
# 지진의 깊이를 3영역으로 구분하여 카운팅
depthgroup<-equal.count(quakes$depth, number=3, overlap=0)
depthgroup
#Intervals:
#    min    max count
#1   39.5 139.5    335
#2 138.5 498.5    338
#3 497.5 680.5    334
```

lattice 패키지

```
# depthgroup변수 기준으로 플로팅
xyplot(lat ~ long | depthgroup, data=quakes,
        main="Fiji Earthquakes(depthgruop)",
        ylab="latitude", xlab="longitude", pch=".",col='red')
```

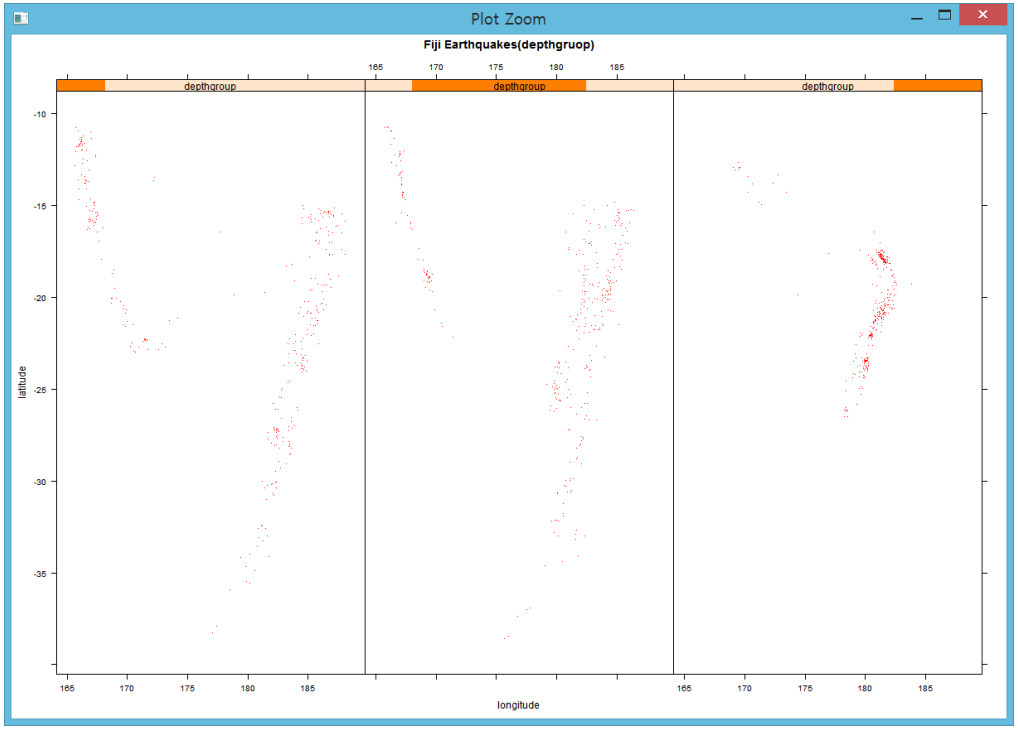

lattice 패키지

```
# depthgroup기준 - 3행 2열
xyplot(lat ~ long | magnitude*depthgroup, data=quakes,
        main="Fiji Earthquakes",
        ylab="latitude", xlab="longitude",
        pch="@",col=c("red","blue"),
        scales=list(x=list(alternating=c(1,1,1))),
        between=list(y=1),
        par.strip.text=list(cex=0.7),
        par.settings=list(axis.text=list(cex=0.7)))

# 추가 옵션
# scales=list(x=list(alternating=c(1,1,1))) : x축 이름 아래쪽 일괄 배치
# between=list(y=1) : y축 사이 여백
# par.strip.text=list(cex=1.2) : 그룹 변수명 텍스트 크기
# par.settings=list(axis.text=list(cex=1.2)) : 축이름 텍스트 크기
```

lattice 패키지

7. cloud() -> 3차원(z ~ y * x) 산점도 그래프 플로팅

```
cloud(depth ~ lat * long , data=quakes,
        zlim=rev(range(quakes$depth)),
        xlab="경도", ylab="위도", zlab="깊이")
```

depth ~ lat * long : depth(z축), lat(y축) * long(x축)

zlim=rev(range(quakes$depth)) : z축값 범위 지정

panel.aspect=0.75 : 테두리 사이즈

screen=list(z=105,x=-70) : z,x축 회전

xlab="Longitude" : x축 이름

ylab="Latitude" : y축 이름

zlab="Depth" : z축 이름

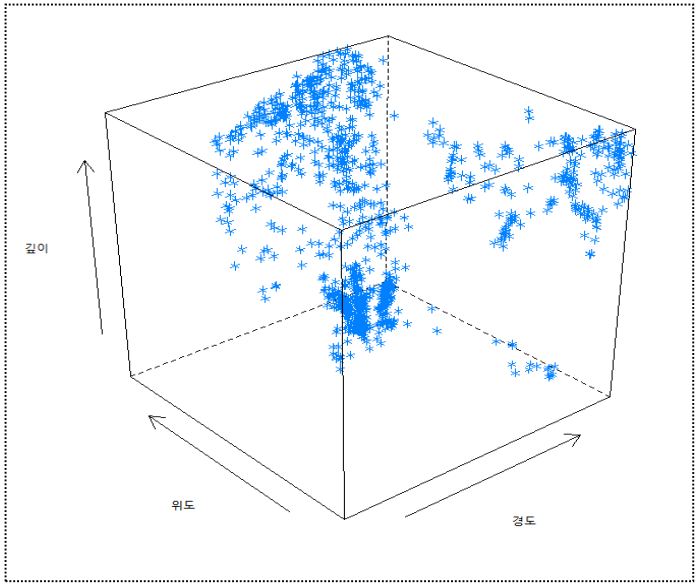

ggplot2 패키지

- ggplot2 그래픽 패키지 특징
  - ✓ 기하학적 객체들(점,선,막대 등)에 미적 특성(색상, 모양,크기)를 맵핑하여 플로팅한다.
  - ✓ 그래픽 생성 기능과 통계변환을 포함할 수 있다.
  - ✓ ggplot2의 기본 함수 qplot()-aesthetics(크기,모양,색상)과 geoms(점,선 등)으로 구성

ggplot2 패키지

- ggplot2 레이어 구조 이해하기

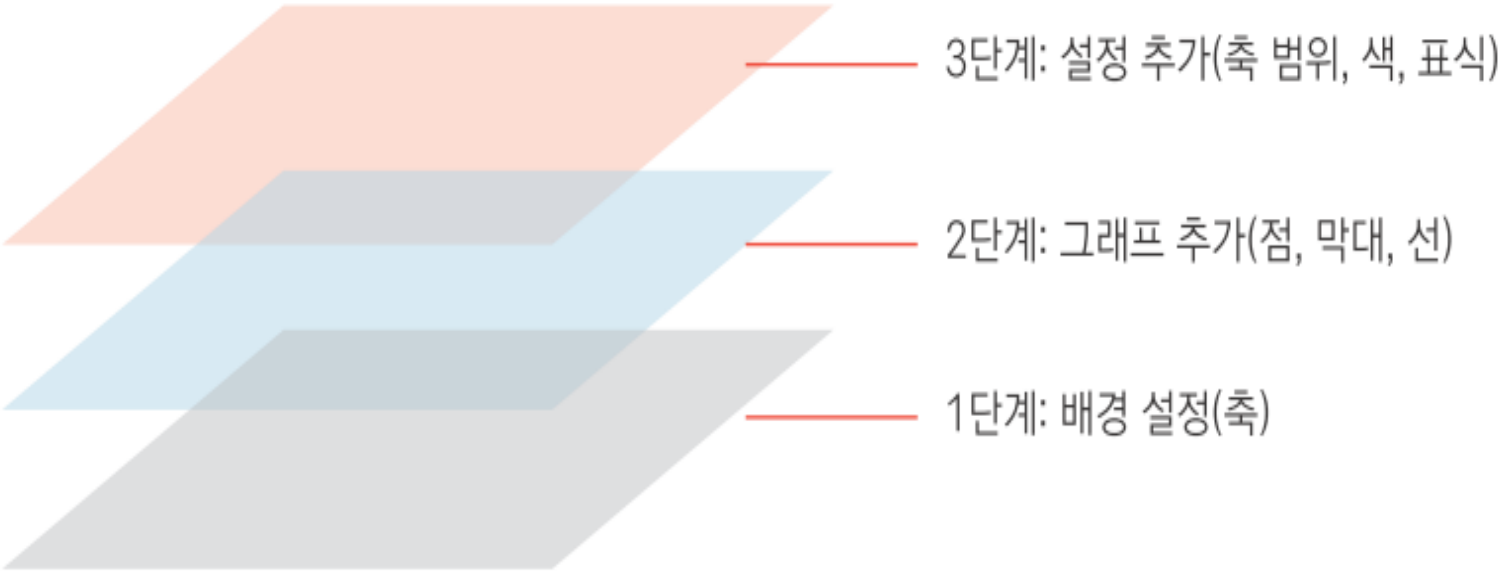

ggplot2 레이어 구조

ggplot2 패키지

- ggplot2 package 및 데이터 셋 설치

```
# ggplot2 패키지는 데이터프레임 데이터를 이용(변환 요구)
install.packages("ggplot2")
library(ggplot2)
str(mpg)
head(mpg)
# manufacturer model displ year cyl     trans drv cty hwy fl    class

################## mpg 데이터셋 ##################
#  ggplot2에서 제공하는 데이터셋
#  'data.frame':        234 obs. of  11 variables:
#  주요 변수 : displ:엔진크기, cyl : 실린더수,
#            drv(구동방식) ->사륜구동(4), 전륜구동(f), 후륜구동(r)
##################################################
```

ggplot2 패키지

- gplot(x, y, data)함수 이용 플로팅

qplot(displ, hwy, data=mpg) # mpg 데이터셋의 displ과 hwy변수 이용
displ(x):엔진크기, hwy(y):고속도로 주행

qplot(displ, hwy, data=mpg, color=drv) # drv변수값으로 색상적용
drv -> 사륜구동(4) : red, 전륜구동(f):green, 후륜구동(r):blue,

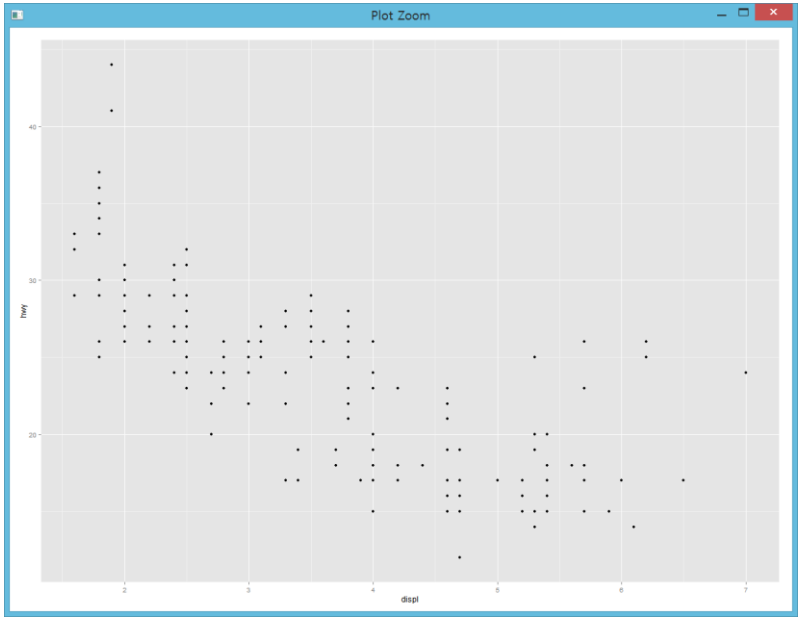

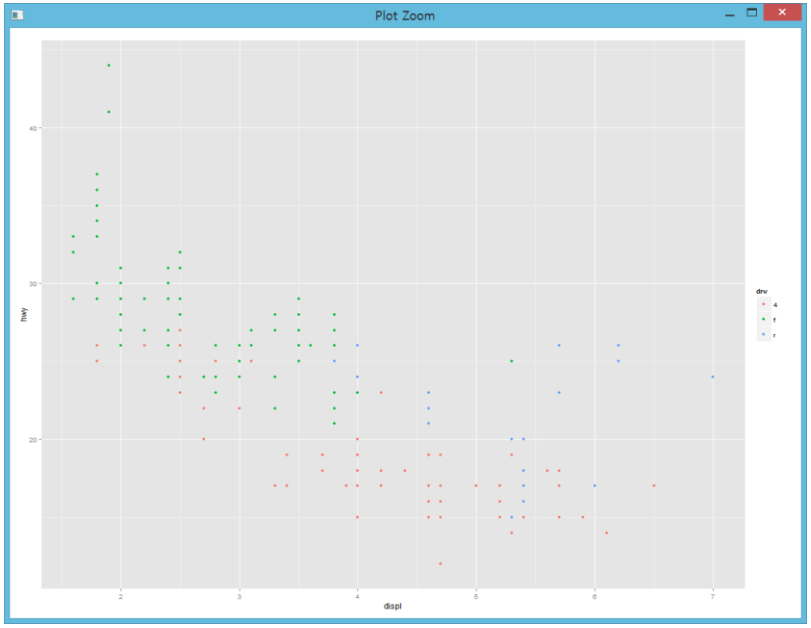

ggplot2 패키지

- 1개 변수 대상 히스토그램 플로팅

```
qplot(hwy, data=mpg, fill=drv) # hwy변수 대상 drv 색상 적용
# 각 그룹별 히스토그램 분포를 플로팅 한다.(fill : 색채우기)
# drv 기준으로 hwy의 빈도수를 플로팅
# 예) drv가 f이고, hwy가 29인 경우가 22회가 발생함
# 설명) 고속도로 주행 속도가 29이고, 전류구동인 경우 22회 발생
```

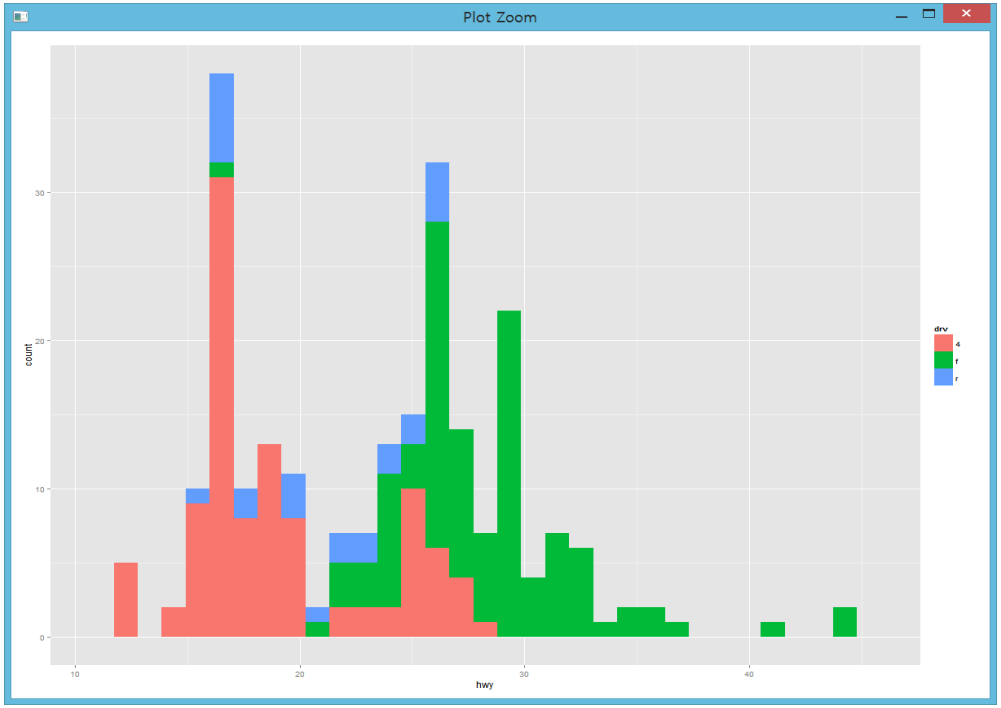

ggplot2 패키지

- 1개 변수 대상 히스토그램 플로팅- binwidth=막대굵기

```
qplot(hwy, data=mpg, facets=.~ drv, binwidth=2) # 열 단위

qplot(hwy, data=mpg, facets=drv~., binwidth=2) # 행 단위
```

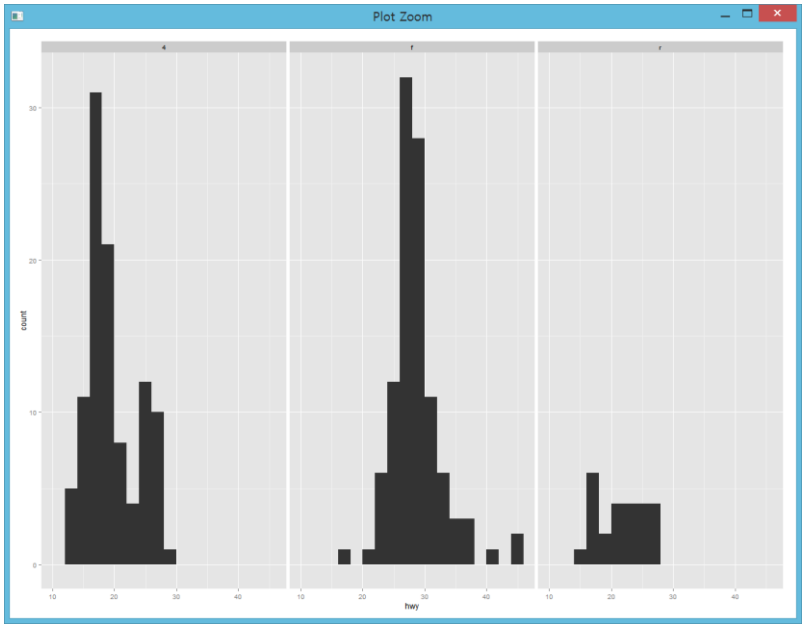

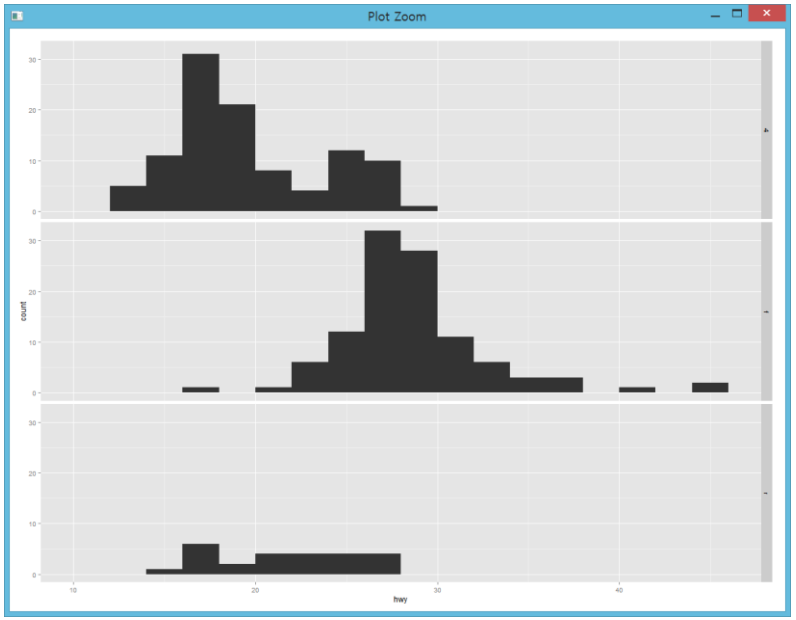

ggplot2 패키지

- 2개 변수 간의 관계분석

```
# 엔진크기와 고속도로 주행속도와의 관계를 구동방식으로 구분
qplot(displ, hwy, data=mpg, facets=.~ drv)
# facets : dataset에서 특정 부분집합만 취합해서 플로팅
# Factor변수에 의해서 그려진다. - drv값을 요인변수로 사용
```

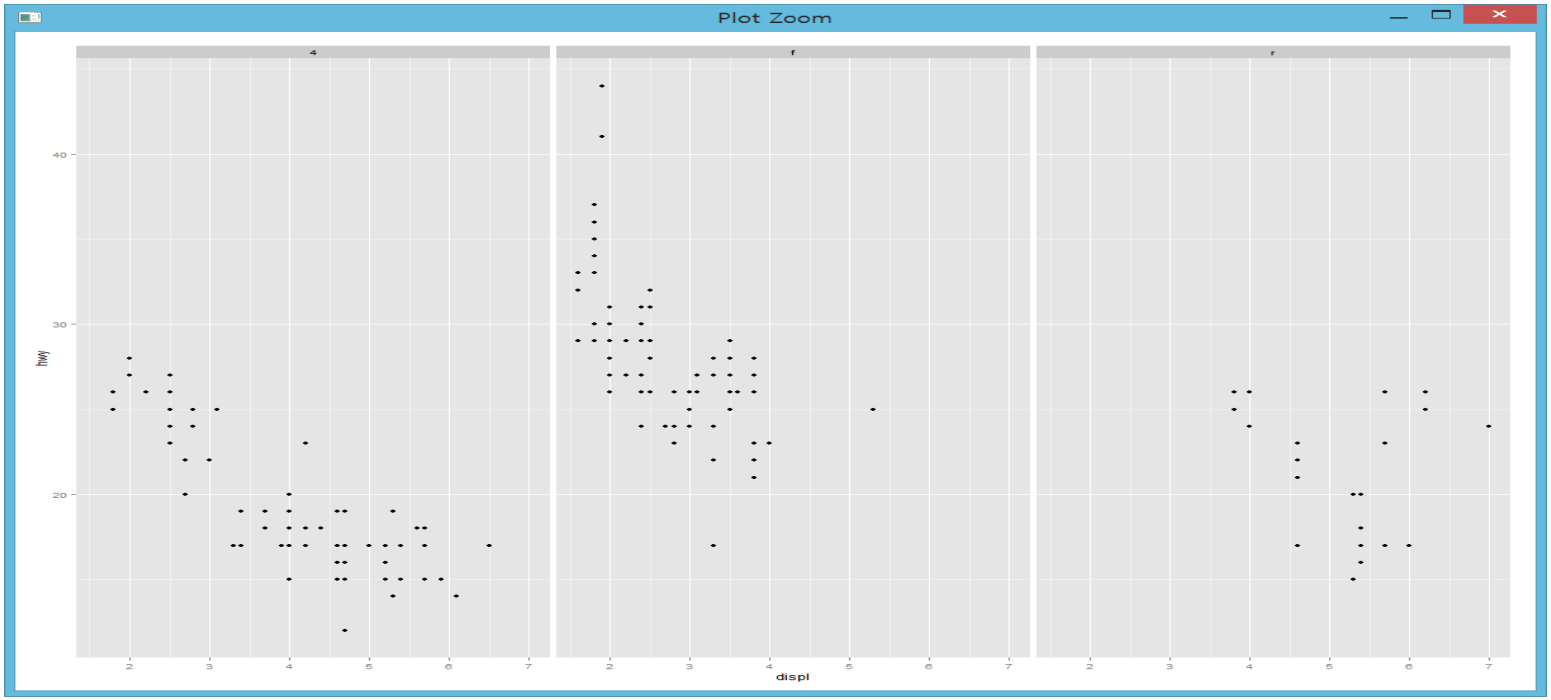

ggplot2 패키지

- geom="bar"

```
head(diamonds) # ggplot2에서 제공하는 데이터 셋
qplot(clarity, data=diamonds, fill=cut, geom="bar")
```

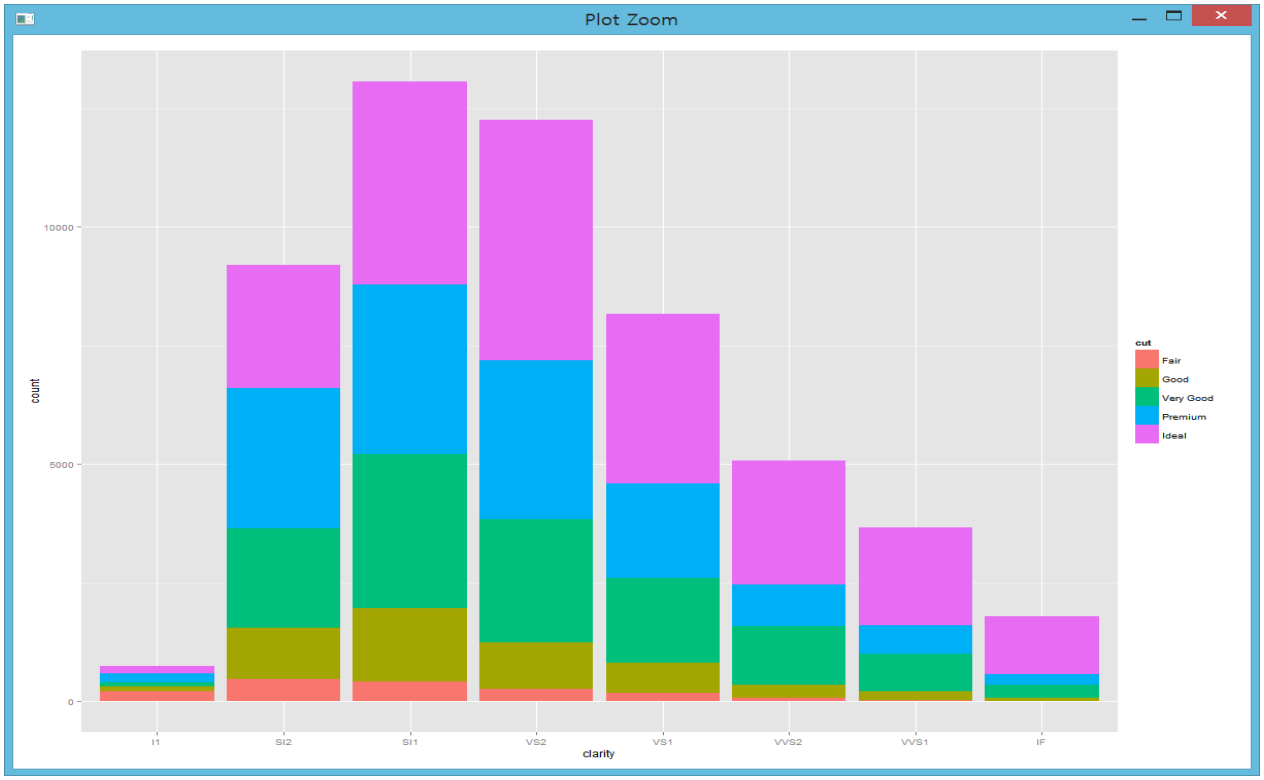

ggplot2 패키지

- 다양한 bar 차트 유형

```
qplot(clarity, data=diamonds, geom="bar", fill=cut, position="stack")
qplot(clarity, data=diamonds, geom="bar", fill=cut, position="dodge")
qplot(clarity, data=diamonds, geom="bar", fill=cut, position="fill")
```

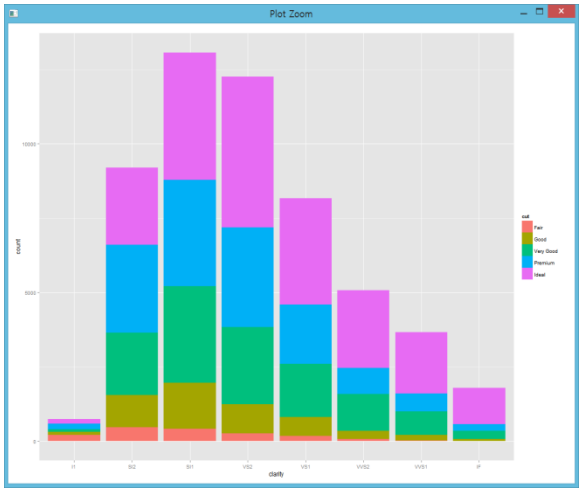

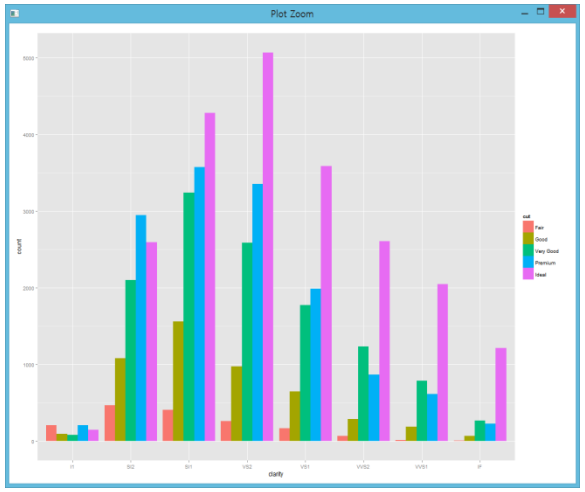

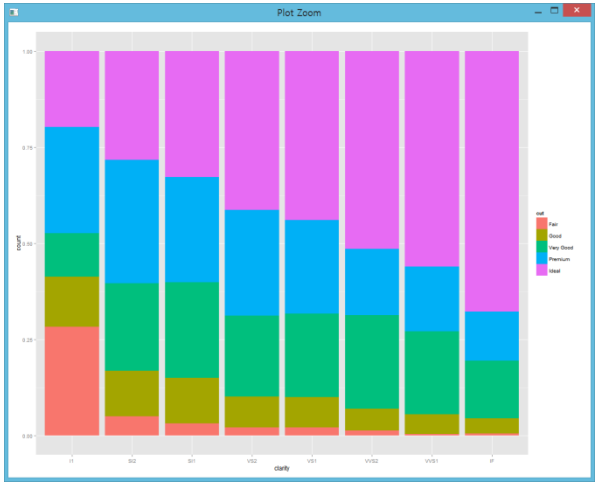

ggplot2 패키지

- 색상과 크기 적용

```
head(mtcars) # ggplot2에서 제공하는 데이터 셋
# qsec 변수 값로 point 크기 지정
qplot(wt, mpg, data=mtcars,  color=factor(carb)) # 색상 적용
qplot(wt, mpg, data=mtcars, size=qsec, color=factor(carb)) # 크기 적용
```

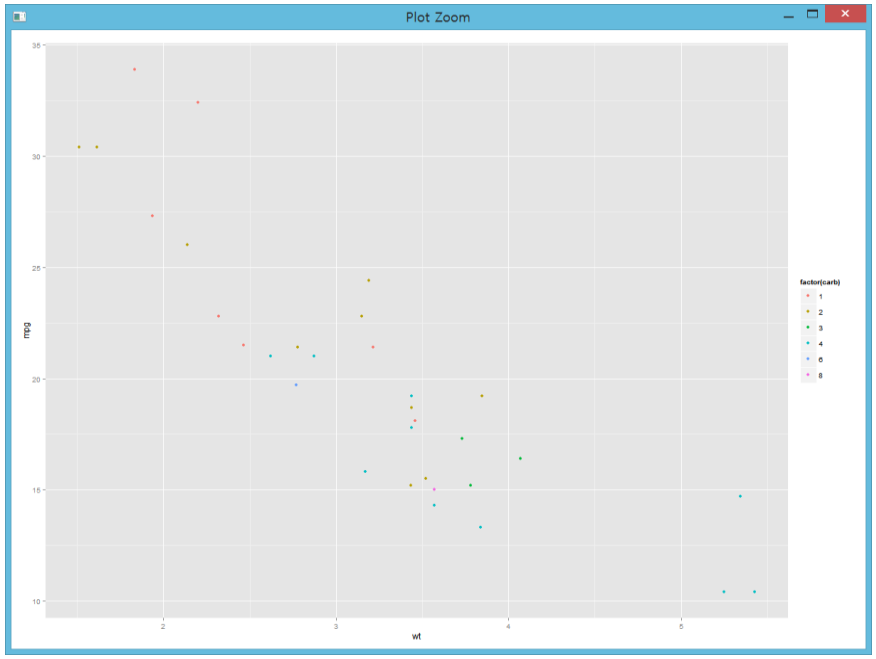

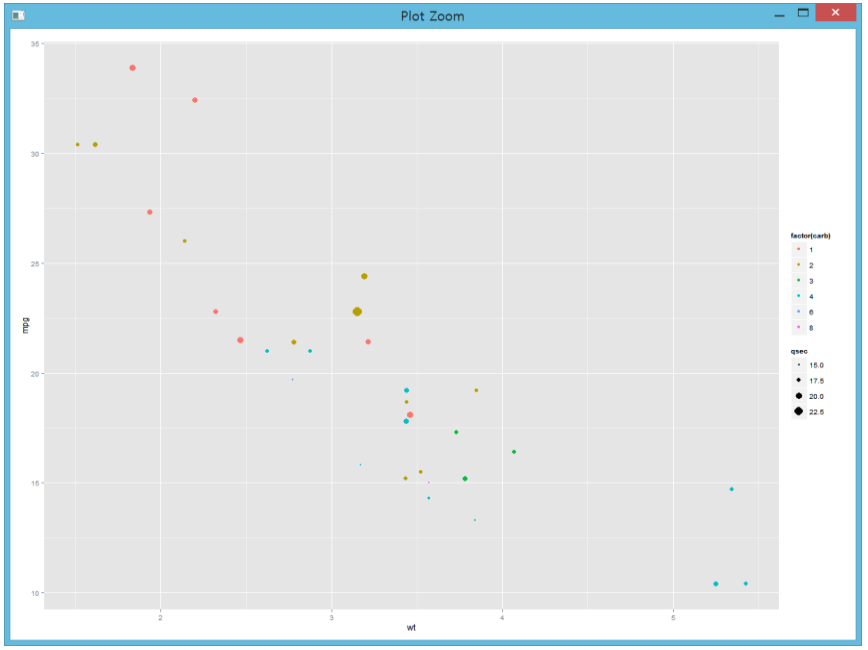

ggplot2 패키지

- geom="point"

```
qplot(wt, mpg, data=mtcars, size=qsec, geom="point")
# cyl 변수의 요인으로 point 크기 지정
qplot(wt, mpg, data=mtcars, size=factor(cyl), geom="point")
# qsec 변수 값로 point 크기 지정, cyl 변수의 요인으로 point 모양 적용
qplot(wt, mpg, data=mtcars, size=qsec, shape=factor(cyl), geom="point")
```

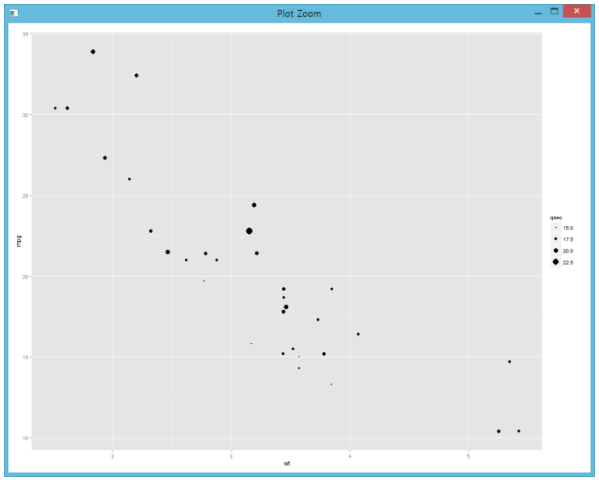

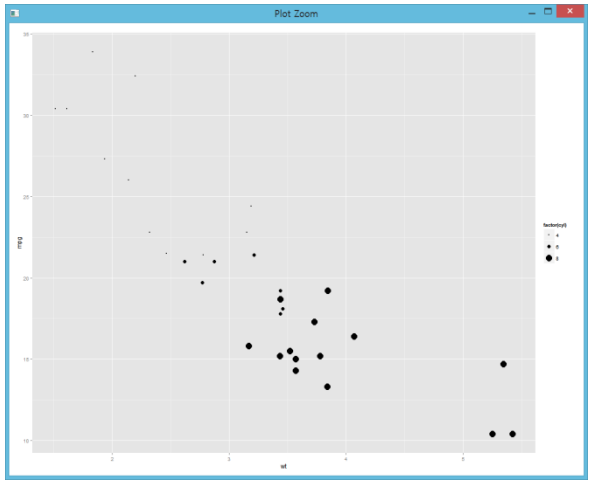

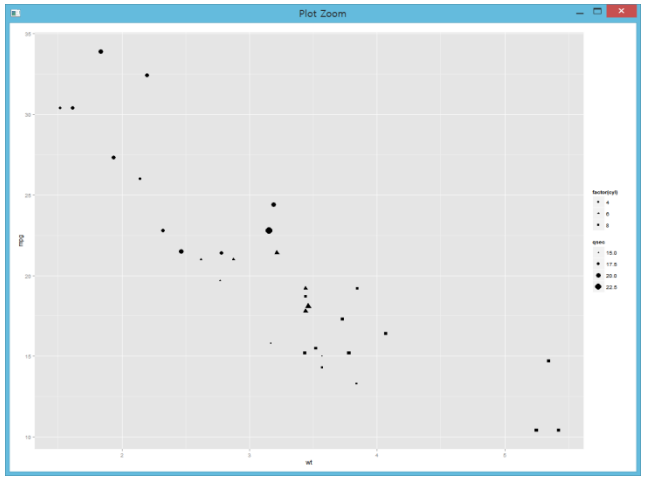

ggplot2 패키지

- geom=c("point", "smooth")

```
qplot(wt, mpg, data=mtcars, geom=c("point", "smooth"))

qplot(wt, mpg, data=mtcars, color=factor(cyl),
    geom=c("point", "smooth")) # cyl변수 요인으로 색상 적용
```

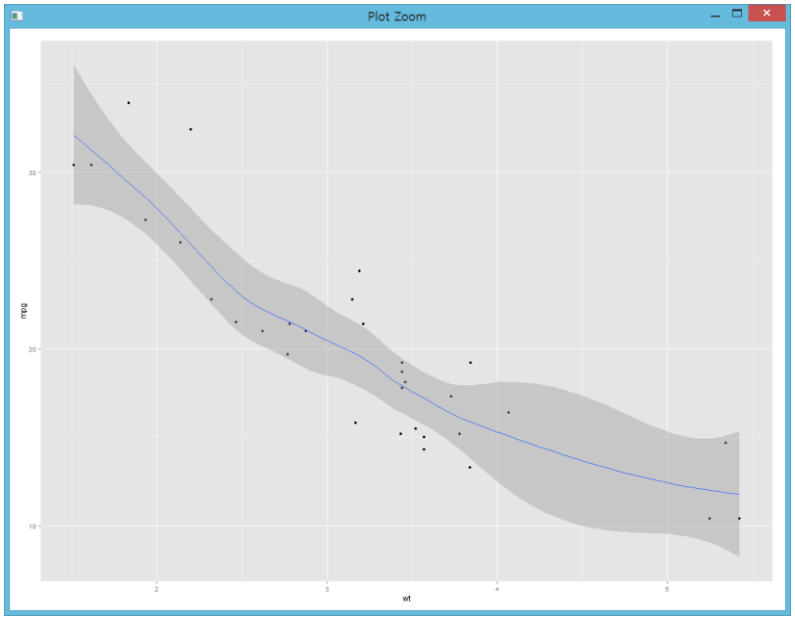

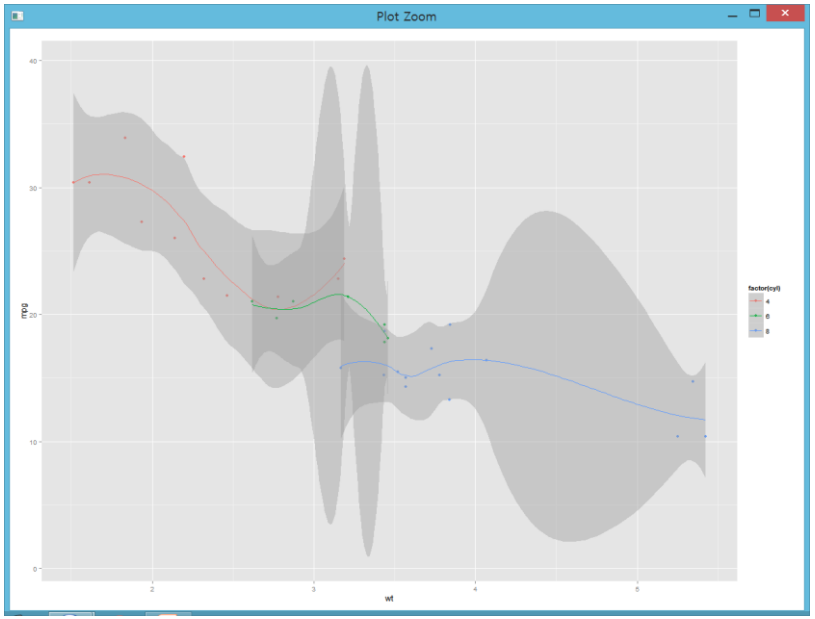

ggplot2 패키지

- geom="freqpoly"

```
qplot(clarity, data=diamonds, geom="freqpoly", group=cut, colour=cut,
      position="identity")
qplot(clarity, data=diamonds, geom="freqpoly", group=cut, colour=cut,
      position="stack")
```

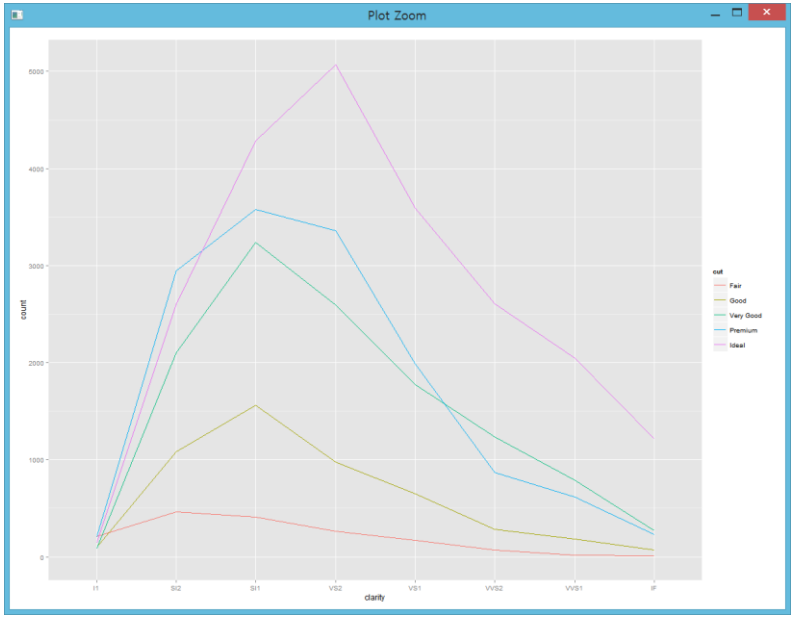

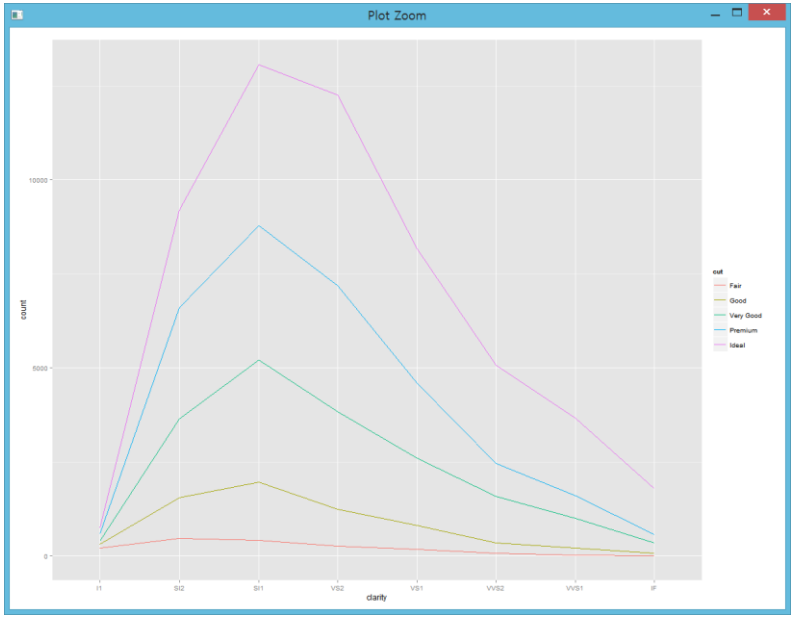

ggplot2 패키지

- geom_line()

```
qplot(mpg, wt, data=mtcars, color=factor(cyl), geom="point") +
geom_line()
qplot(mpg, wt, data=mtcars, color=factor(cyl), geom=c("point","line"))
```

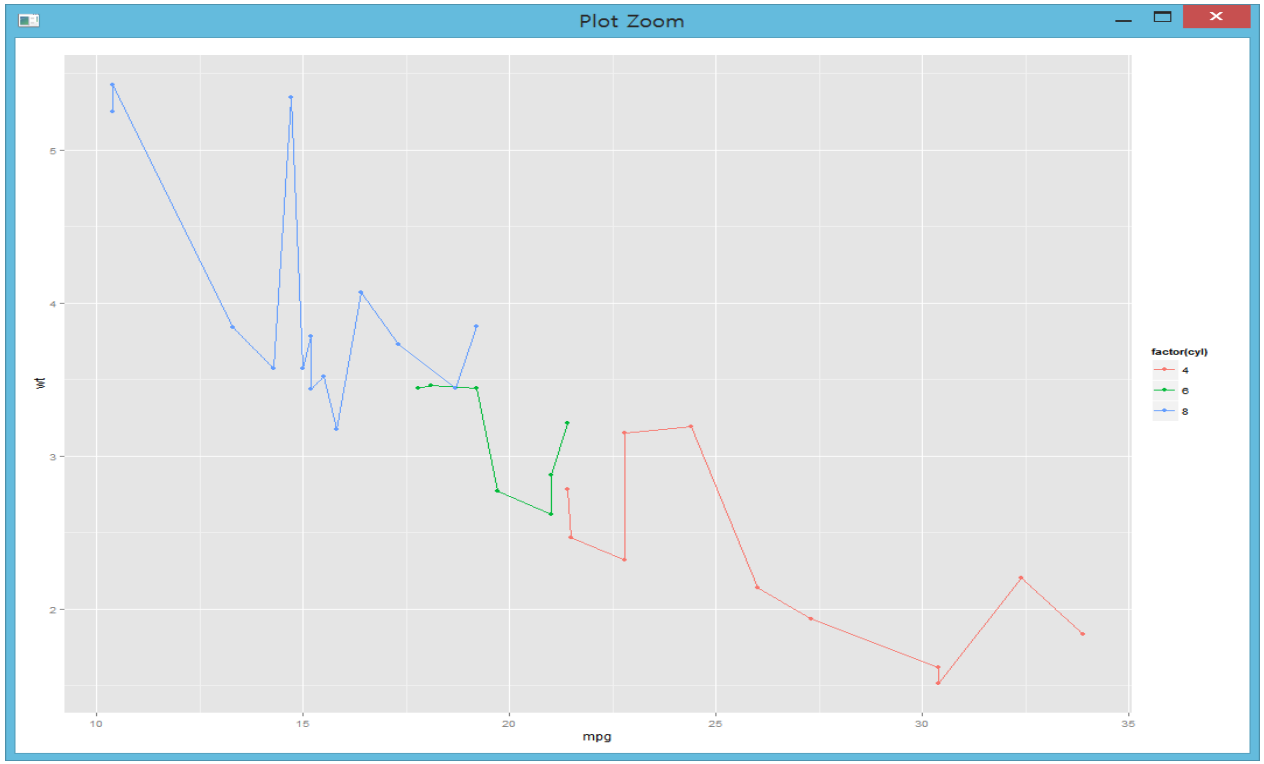

ggplot2 패키지

- aes(x, y, color)

```
p<-ggplot(diamonds, aes(carat, price, color=cut))
p<-p+layer(geom="point") # point 추가
plot(p)
```

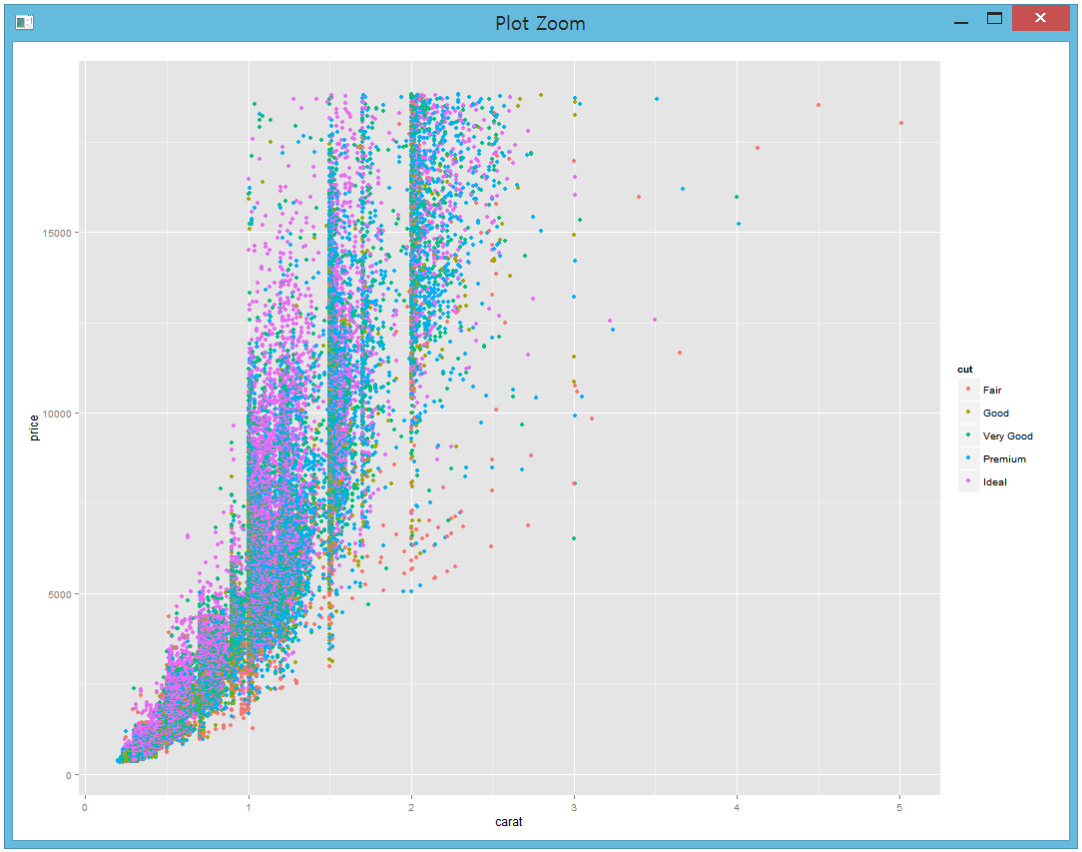

ggplot2 패키지

➢ 그래프 저장

```
ggsave(file="C:/workspaces/Rwork/output/test.pdf") # 가장 최근 그래프 저장
ggsave(file="C:/workspaces/Rwork/output/test.jpg", dpi=72)
# 변수에 저장된 그래프 저장
ggsave(file="C:/workspaces/Rwork/output/test.png", plot=p, width=10, height=5)
```

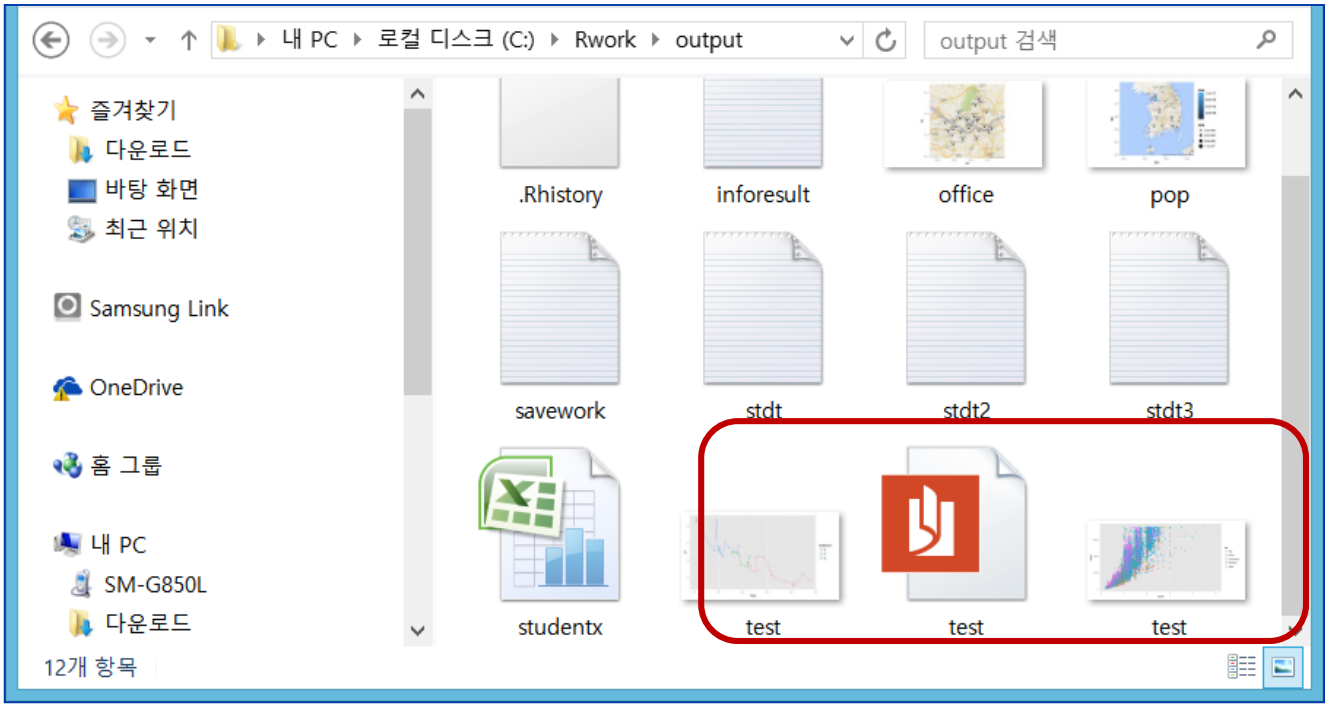

공간시각화

➢ 공간시각화 특징

- ✓ 공간 시각화는 지도를 기반으로 하기 때문에 위치, 영역, 시간과 공간에 따른 차이 및 변화에 대한 것을 다룸
- ✓ 위치 : 위도 및 경도, 지도에 버블로 표현
- ✓ 영역 : 데이터에 따른 색상으로 표현
- ✓ 시·공간 : 레이어 형태로 추가하여 시각화

공간시각화

- ggmap package 설치

```
# 지도 관련 패키지 설치
install.packages("ggmap") # 'ggmap'와 'ggplot2' 관련 패키지
library(ggmap)
Warning messages:
1: 패키지 'ggmap'는 R 버전 3.1.3에서 작성되었습니다
2: 패키지 'ggplot2'는 R 버전 3.1.3에서 작성되었습니다
```

공간시각화

- google 지도 불러오기

```
map <- get_googlemap("Jeonju", zoom=14, maptype='satellite', scale=2)
# scale=2 : 선명도 좋아짐
ggmap(map, size=c(600,600), extent='device') #장치 허용크기로 표시
```

공간시각화

- get_map()과 ggmap() 함수 사용

```
# 실습 데이터 가져오기
loc <- read.csv("C:/workspaces/Rwork/data/seouloffice.csv",header=T)
loc # 구청명       LON(위도)       LAT(경도)
# get_map("중심지역", 확대비율, 지도유형) : ggmap 패키지 제공 함수
kor <- get_map("seoul", zoom=11, maptype = "roadmap") # 지도정보
# maptype : roadmap, satellite, terrain, hybrid


# 지도 정보로 지도 플로팅
ggmap(kor)
```

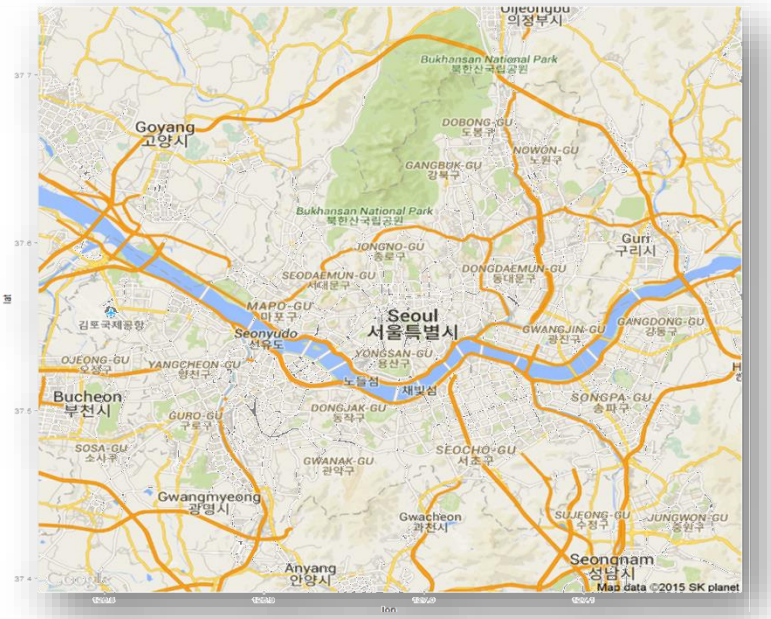

공간시각화

- 레이어 기법으로 공간 시각화 결과화면

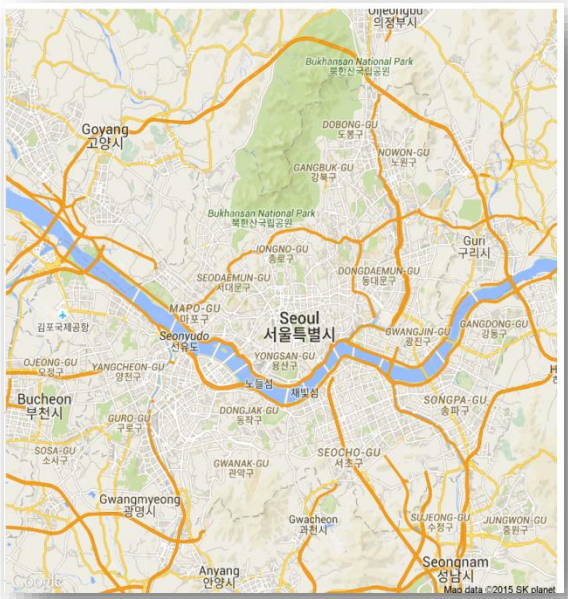

레이어1 : 지도

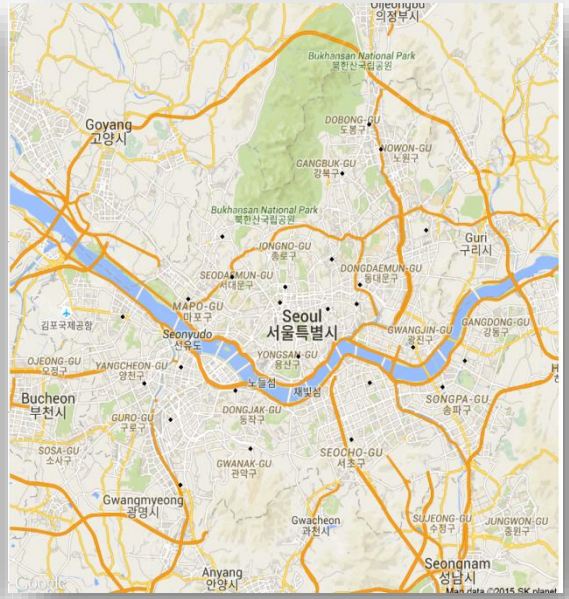

레이어2 : 포인트 추가

레이어3 : 지역명 추가

공간시각화

- 레이어 기법으로 공간 시각화

레이어1 : 지도 -> 레이어2 : 지도위에 포인트

ggmap(kor)+geom_point(data=loc, aes(x=LON, y=LAT),size=3)

ggmap(kor) : 지도정보로 지도 플로팅, + geom_point() : 포인트(◈) 추가

+ : 지도 위에 레이어 형태로 포인트 추가

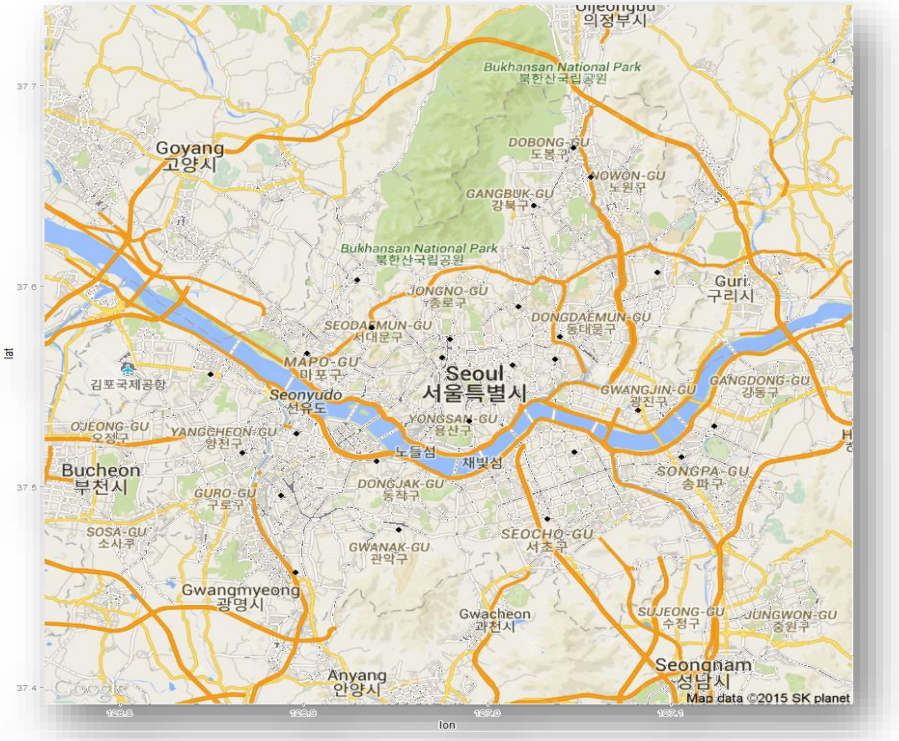

공간시각화

kor.map <- ggmap(kor)+geom_point(data=loc, aes(x=LON, y=LAT),size=3)

geom_point() : ggplot2에서 제공하는 함수

레이어 3: 지도 위에 포인트 위에 텍스트(구청명) 표시

kor.map+geom_text(data=loc, aes(x=LON, y=LAT+0.01,label=구청명),size=3)

LAT+0.01 : 텍스트 위치(포인트의 0.01 위쪽)

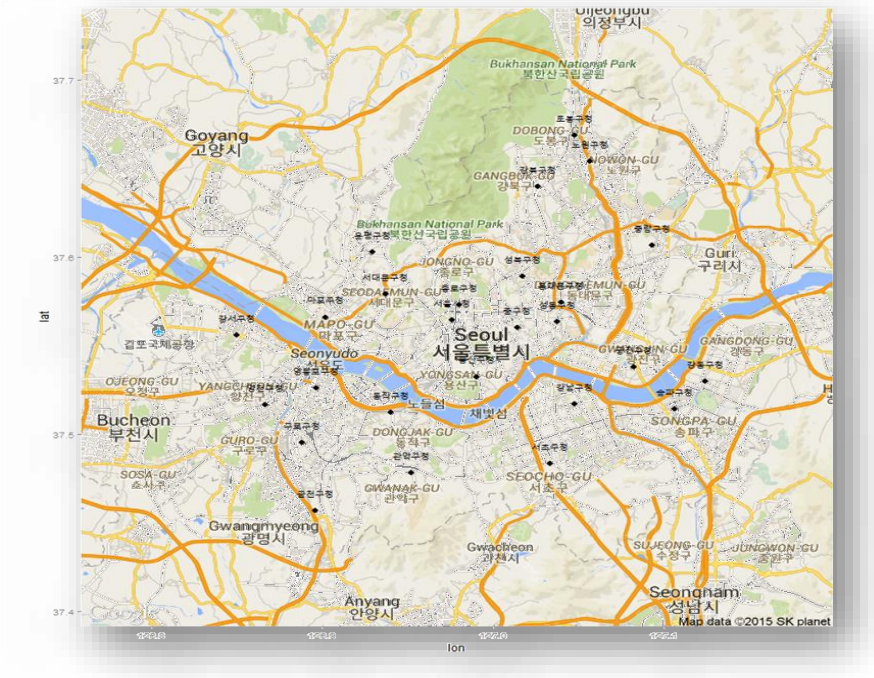

공간시각화

➢ 지도 이미지 파일로 저장

ggsave() : 현재 plots창의 지도를 이미지 파일로 저장 함수

ggsave("C:/workspaces/Rwork/output/office.png", dpi=500)

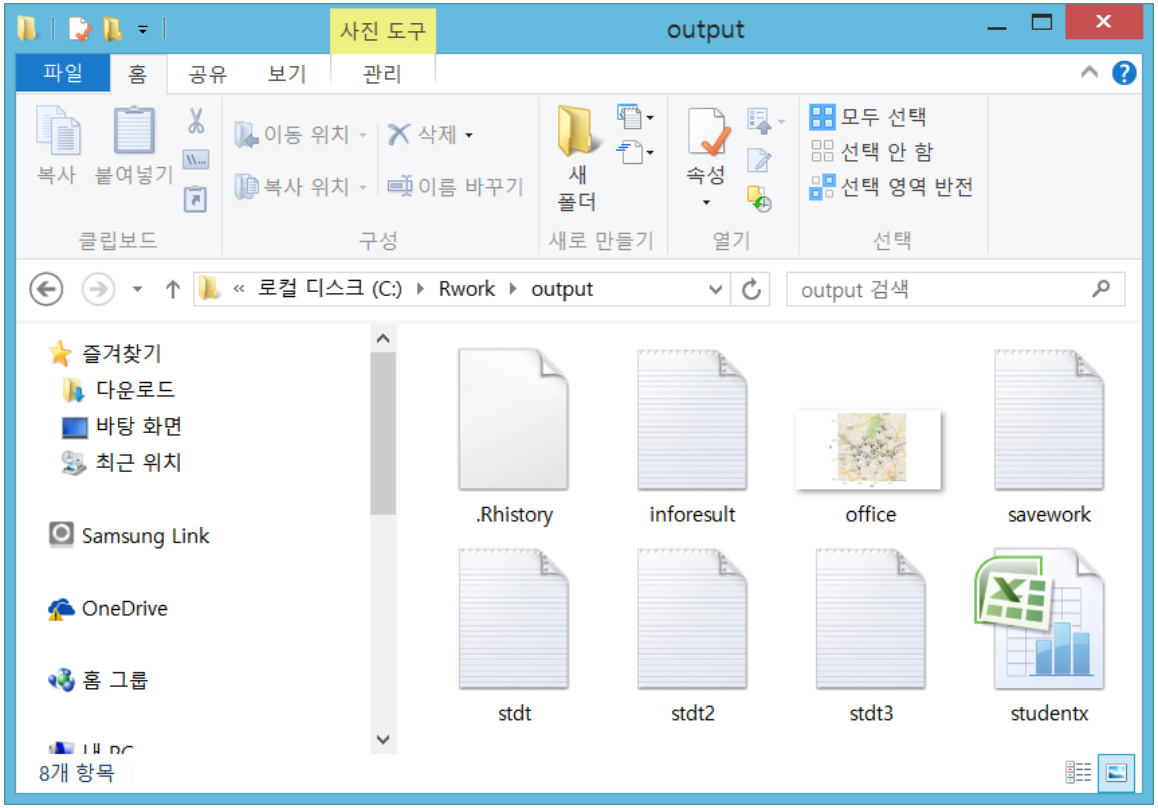

공간시각화

- 공간시각화 실습

```
########## 공간시각화 실습 데이터 가져오기 ############
pop <- read.csv("C:/workspaces/Rwork/data/population2014.csv",header=T)
pop

lon <- pop$LON
lat <- pop$LAT
data <- pop$총인구수

# 위도,경도,총인구수 이용 데이터프레임 생성
df <- data.frame(lon,lat,data)
df
# 지도정보 생성
map <- get_map("Jeonju", zoom=7 , maptype='roadmap')

# 레이어1: 지도 플로팅
map1 <- ggmap(map)
map1
```

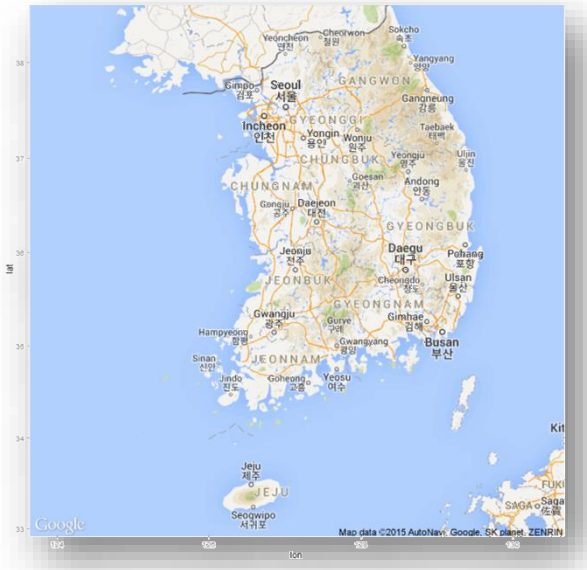

공간시각화

- 공간시각화 실습

```
# 레이어2 : 포인트 추가
map1 + geom_point(aes(x=lon,y=lat,colour=data,size=data),data=df)
# 크기, 넓이, 폭, 밀도 적용 파일 저장
ggsave("c:/workspaces/Rwork/output/pop.png",scale=1,width=7,height=4,dpi=1000)
```

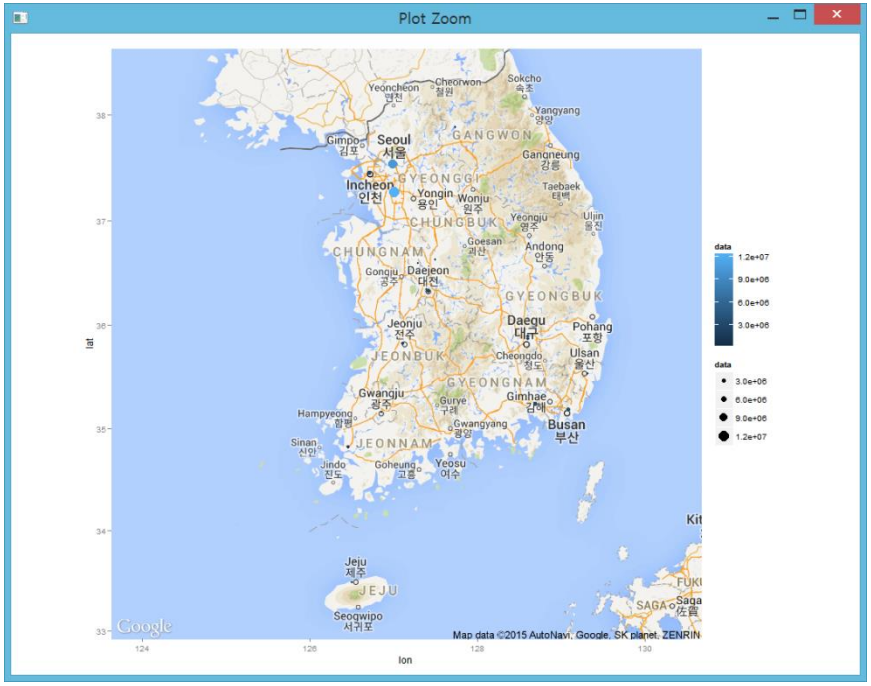

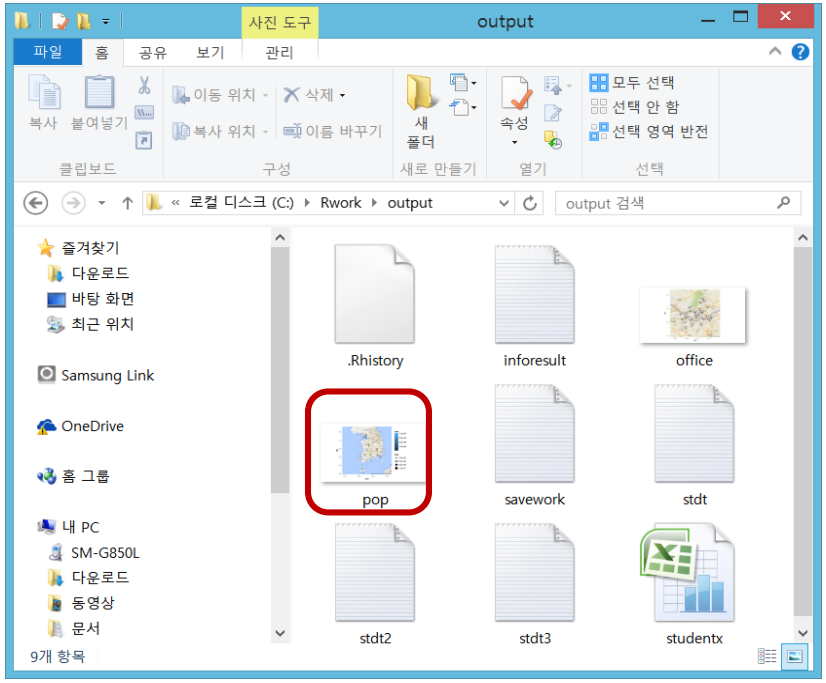

공간시각화

- 다양한 지도 유형

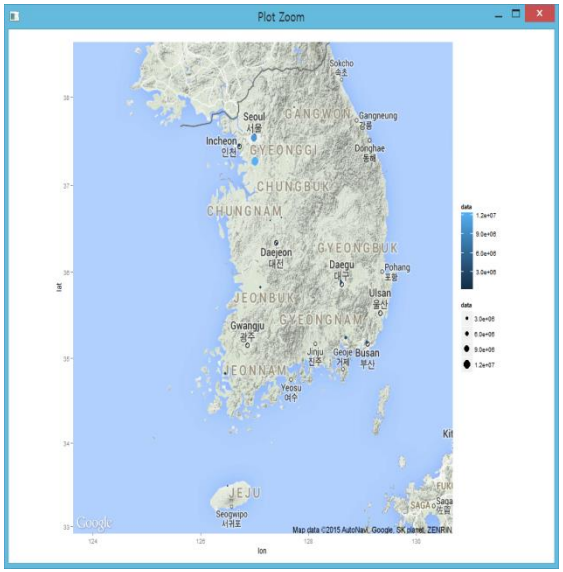

maptype='terrain'

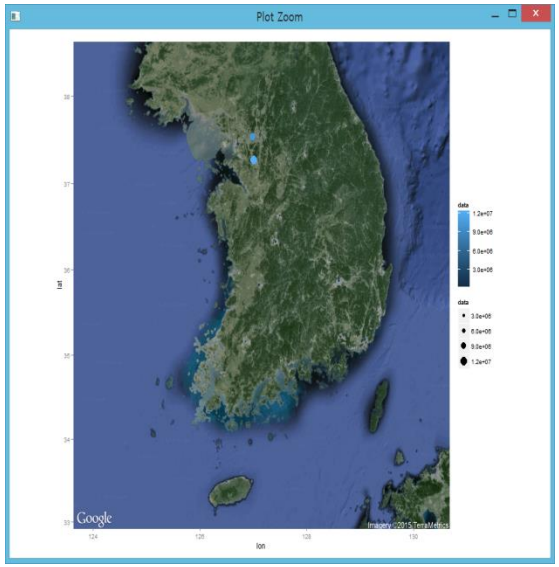

maptype='satellite'

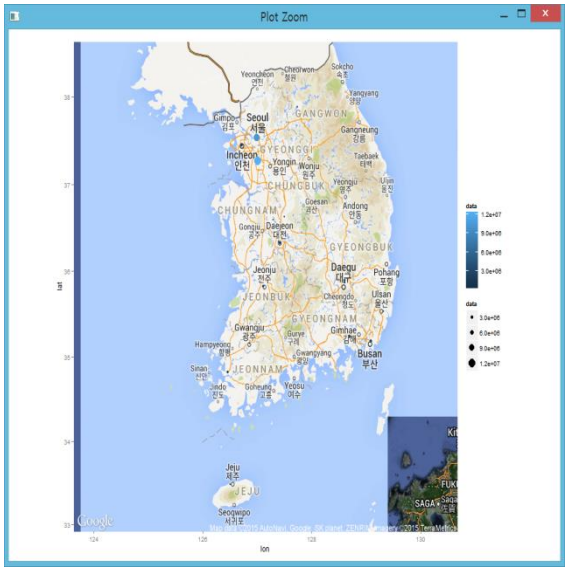

maptype='hybrid'

공간시각화

- stat_bin2d() 함수

```
# stat_bin2d() : 버블모양 적용함수, 인구수(data) 기준 색 적용
map5 <- get_map("Jeonju",zoom=7 , maptype='hybrid')
map5 <- ggmap(map5)
map5 + stat_bin2d(aes(x=lon,
                      y=lat,colour=data,
                      fill=factor(data),
                      size=data),
                      data=df)
```